



分 类 号: TN958

学校代码: 11066

学 号: 202100357018

烟台大学

硕 士 学 位 论 文

基于深度学习的毫米波雷达非接触心率检测技术研究

**Deep learning-based millimeter-wave radar non-
contact heart rate detection technology research**

研 究 生 姓 名: 李洪飞

指 导 教 师: 刘云学教授

学 科 门 类: 工学

学 科 名 称: 电子科学与技术

论文提交日期: 2024 年 6 月 6 日

摘要

雷达提取的生命特征信号中,心跳信号是极其微弱的,而且还存在呼吸的基波及谐波、杂波、差拍、噪声和其他干扰,特别是身体运动引起的干扰,让雷达非接触心率测量检测变得非常之困难。在本研究中,以线性调频连续波雷达为基础,提出了一种新的系统方法,用于心跳信号的提取、判别、滤除干扰以及心率估计。这一方法利用深度学习对目标状态进行识别,智能地选择递归最小二乘算法(Recursive Least Squares, RLS)自适应滤波的参考信号,构建基于变分模式提取(Variational Mode Extraction, VME)和智能 RLS 滤波器的信号提取和干扰抑制模块,并通过卡尔曼滤波将时域和频域的心率估计进行融合,提高了心率估计的精度及其鲁棒性,并证明了其可行性和优越性。以下是论文的主要工作和创新点:

(1)除了常规的信号预处理措施外,本文采用了 VME 结合 RLS 自适应滤波器来进行心跳信号提取和干扰抑制。然而,对于心跳测量来说,运动的状态不同,自适应滤波器的参考信号是不同的。本文将深度学习应用于非接触心率检测领域的目标运动状态判别,并根据判别结果选择参考信号。该方法利用小波散射网络(Wavelet Scattering Network, WSN)对不同状态下心跳信号的特征进行提取,然后通过长短期记忆网络(Long Short-Term Memory Network, LSTM)进行分类。经 VME 提取出来的实际心跳信号输入 WSN-LSTM 网络模型构建的判别器进行判断,以判别当前心跳信号的状态。继而通过基于 RLS 的自适应滤波器,根据判别器输出的心跳信号状态,在 Physio Net 的 ECG-ID 数据库中挑选出与之对应的参考信号。当被测人静止时,从人体静止心跳信号数据库中选择人体处于静止状态下的心跳信号;相反,如果被测人处于微动中,则从人体运动状态下心跳信号数据库中选择运动状态下的心跳信号。

(2)经过 VME 和智能 RLS 自适应滤波器提取的心跳信号,仍然存在噪声和干扰,难以得到精确的心率估计。为此,本文提出了一种基于卡尔曼滤波(Kalman Filter, KF)的时域和频域心率联合估计和融合的方法。首先,通过峰-谷差值算法

(Peak-Valley Difference, PVD)进行时域估计。与此同时，对分离出的心跳信号进行线性调频 Z 变换(Chirp Z-Transform, CZT)谱分析以得到心率的频域估计。最后通过卡尔曼滤波将以上时域和频域的心率估计值进行匹配融合得到心率估计值，极大提高了所获得心率值的准确性和鲁棒性。

(3)将以上所使用的雷达信号预处理流程、VME算法、WST-LSTM模型、基于RLS算法的自适应滤波器以及基于卡尔曼滤波的心率估计方法相结合，形成了一个完整的基于深度学习的毫米波雷达非接触生命体征检测方案。在真实雷达检测场景检测过程，提出的心率检测方案在被测者处于静止状态时，平均绝对误差(Mean Absolute Error, MAE)小于 1.36 次/每分钟；而在被测者运动状态下，该方案的 MAE 为 2.29 次/每分钟。这一结果表明，该方案在不同状态下均表现出了高度的准确性与稳定性。

关键词：心率检测；毫米波雷达；WST-LSTM 网络；RLS 自适应滤波；数据融合

Abstract

Among the life feature signals extracted by radar, the heartbeat signal is extremely weak, and the presence of respiratory fundamental and harmonics, clutter, differential beats, noise, and other interferences, especially those caused by body motion, makes radar non-contact heart rate measurement detection very difficult. In this study, we propose a new systematic approach based on linear FM continuous wave radar for heartbeat signal extraction, discrimination, interference filtering, and heart rate estimation. This method utilizes deep learning to identify the target state, intelligently selects the reference signal for RLS adaptive filtering, constructs a signal extraction and interference suppression module based on VME and intelligent RLS filter, and fuses the heart rate estimation in the time and frequency domains through Kalman filtering, which improves the accuracy of the heart rate estimation and its robustness, and proves its feasibility and superiority. The following are the main work and innovations of the thesis:

(1) In addition to conventional signal preprocessing measures, this paper employs a VME combined with an RLS adaptive filter for heartbeat signal extraction and interference suppression. However, for heartbeat measurement, the reference signal of the adaptive filter is different for different states of motion. In this paper, deep learning is applied for the first time to discriminate the target motion state in the field of non-contact heart rate detection and select the reference signal based on the discrimination result. The method utilizes Wavelet Scattering Network (WSN) to extract the features of heartbeat signals in different states, and then classifies them by Long Short-Term Memory Network (LSTM). The actual heartbeat signals extracted by VME are input into the discriminator constructed by the WSN-LSTM network model, and the wavelet scattering coefficients of the actual heartbeat signals extracted by WSN are matched with ECG signals in different states in the ECG database in order to discriminate the state of the current heartbeat signals. Following that, through an adaptive filter based on the least squares

algorithm (RLS), a reference signal corresponding to the heartbeat signal is selected in the ECG-ID database of Physio Net according to the state of the heartbeat signal output from the discriminator. When the subject is at rest, the heartbeat signal when the human body is at rest is selected from the database of human resting heartbeat signals; on the contrary, if the subject is in micro-motion, the heartbeat signal in motion is selected from the database of heartbeat signals when the human body is in motion.

(2) The heartbeat signal extracted by VME and intelligent RLS adaptive filter still has noise and interference, which makes it difficult to obtain accurate heart rate estimation. For this reason, this paper proposes a joint estimation and fusion method of heart rate in time and frequency domains based on Kalman Filter (KF). First, the time domain estimation is performed by Peak-Valley Difference (PVD) algorithm. At the same time, the separated heartbeat signals were analyzed by linear FM Z-transform (CZT) spectral analysis to obtain the frequency domain estimation of heart rate. Finally, the above time-domain and frequency-domain heart rate estimates were matched and fused by Kalman filtering to obtain the heart rate estimates, which greatly improved the accuracy and robustness of the obtained heart rate values.

(3) We combined the radar signal preprocessing pipeline, the WST-LSTM model, the adaptive filter based on the RLS algorithm, and the heart rate estimation method based on the Kalman Filter to construct a complete AI-based millimeter-wave radar non-contact vital sign detection solution. Through real human experiments, the proposed heart rate detection solution achieved an average absolute error of less than 1.36 beats per minute when the subjects were in a stationary state, and 2.29 beats per minute when they were in motion. This result demonstrates the high accuracy and stability of the proposed solution under different conditions.

Keywords: heart rate detection; mm-wave radar; WST-LSTM; RLS adaptive filtering; KFTF method

目 录

1 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	2
1.3 论文主要工作及结构安排	4
2 毫米波雷达生命体征检测理论研究	7
2.1 FMCW 雷达目标检测原理	7
2.1.1 锯齿波 FMCW 信号分析	7
2.1.2 中频信号的相位对胸腔运动的敏感性	9
2.2 雷达信号预处理.....	9
2.2.1 距离维 FFT.....	10
2.2.2 静态杂波滤除.....	11
2.2.3 目标人体所在距离单元选择.....	13
2.2.4 相位解缠.....	14
2.3 生命体征信号建模.....	16
2.4 模态分解类算法.....	18
2.4.1 EMD 算法及仿真分析.....	18
2.4.2 VMD 算法及仿真分析	20
2.4.3 VME 算法及仿真分析.....	23
2.5 算法性能分析.....	24
2.5.1 信噪比分析.....	25
2.5.2 运行时间分析.....	26
2.6 本章小结.....	27
3 基于深度学习的干扰抑制算法	28
3.1 小波散射网络.....	28
3.2 长短期记忆网络.....	32
3.3 自适应滤波去噪算法.....	36
3.4 实验结果分析.....	40
3.5 本章小结.....	43
4 基于卡尔曼滤波的时频融合心率估计方法	44
4.1 心跳信号时域估计.....	44
4.2 心跳信号频域估计.....	46
4.3 卡尔曼滤波原理.....	47
4.4 基于卡尔曼滤波的数据融合心率估计方法	49
4.5 本章小结.....	54

5 基于 FMCW 雷达的生命体征检测实验及结果分析	55
5.1 实验设置	55
5.1.1 毫米波雷达	55
5.1.2 数据采集卡	56
5.1.3 参考心率带	57
5.1.4 实验环境	58
5.1.5 参数配置	58
5.1.6 实验评价指标	59
5.2 基于 FMCW 雷达的心率检测处理框架的性能评估	60
5.2.1 静止状态下心率检测结果分析	61
5.2.2 运动状态下心率检测结果分析	63
5.3 本章小结	65
6 总结和展望	66
6.1 研究工作总结	66
6.2 后续研究展望	67
参考文献	68

1 绪论

1.1 研究背景及意义

人体的心跳是生命体征和健康状态的重要指标之一^[1]。因此，对人体心率进行检测具有重要价值。传统的心跳检测方法包括心电图、心音听诊和光电式脉搏测量法^[2]。然而，这些检测设备通常体积较大、成本较高，操作较为繁琐，需要专业人士操作，这极大限制了它们在特定场合和特定群体中的使用。与此同时，随着2023年全国第七次人口普查数据的公布，我国已经明显步入老龄化社会^[3]。大部分家庭进入到了两个成年人养育四个老年人的艰难阶段，老龄化社会的到来不仅带来了巨大的社会经济挑战，也凸显了老年人健康监护的紧迫性。据国内外相关研究，在老年人死亡原因中，心血管疾病是首要因素^[4]。而心血管疾病和心脏病的突发，都会引起心率数据的骤然变化^[5]。因此，对于心率的监控就显得尤为重要^[6]。

随着社会养老压力的不断加大以及人们对健康的关注度持续提高，便携式或可穿戴的生命体征检测设备变得越来越普及，这些设备包括智能手环、智能心率带、腕带式脉搏血氧仪、穿戴式心电采集器等^[7]。虽然现代技术已经实现了许多无创、安全的检测方式，但大多数仍然基于接触式的检测技术^[8]。接触式测量需要传感器与人体接触，可能引起不适感，在特殊场合的使用极为不便，例如：需实时监控的养老院，在浴室和卫生间等不方便的场所、自然灾害的搜救现场^[9-10]。

因此，正如上文所述，我们的社会迫切的需要一种不涉及隐私的、全天候的、检测效果稳定的设备来进行生命体征监测^[11]。其中，调频连续波(Frequency Modulated Continuous Wave, FMCW)雷达不仅具备连续波雷达远距离测量的优点，同时兼具超宽带雷达的距离分辨率高和测量稳定的特点^[12]。此外，FMCW 雷达^[13]集成度高、重量轻、功耗低，具备更高的工程实用性。因此，FMCW 雷达成为非接触式生理信号检测的首选技术。目前该技术应用广泛，主要包含以下几个方面：

(1)生命体征监测：国外研究着重于使用毫米波雷达技术^[14]进行心率、呼吸率、运动等生命体征的非接触式监测。一些研究表明，毫米波雷达可以实现高精度

的生命体征监测，对于床上病患、婴儿和老年人的监测具有潜在的应用前景^[15]。

(2)行为分析：毫米波雷达不仅可以用于生命体征监测，还可以应用于行为分析。通过分析人体运动的微小变化，研究人员能够识别特定的动作、姿势和活动，为健身、运动分析等领域提供数据支持^[16]。

(3)睡眠监测：一些研究着眼于使用毫米波雷达进行睡眠质量的监测。这项技术通过监测睡眠中人体的微动以及呼吸等生理信号，实现对睡眠阶段的自动识别^[17]。

(4)医疗应用：在国内，毫米波雷达技术在医疗领域的应用也备受关注。研究人员尝试将毫米波雷达用于疾病诊断、康复监测等方面^[18]。

(5)智能家居：国内一些企业和研究机构也在探索毫米波雷达在智能家居领域的应用。通过毫米波雷达可以实现人体姿势识别、智能灯光控制等功能，提升家居的智能化水平^[19]。

(6)人机交互：有研究关注毫米波雷达在人机交互中的潜在应用，例如手势识别、面部表情分析等。这些应用可以在虚拟现实、增强现实等领域发挥作用^[20]。

结合以上背景和实际需求，本文依据现有的非接触式生命体征检测内容，重点研究心跳信号的提取、判别，干扰信号的抑制与心率估计。在准确的基础上兼顾性能、实时性和稳定性，可为未来心率检测领域的研究和应用提供有力支持^[21]。

1.2 国内外研究现状

非接触式生命体征检测主要依托于不同的生命体征检测设备^[22]，通过不同的硬件平台对所需的生命体征参数进行测量，目前主要依托于相机、热成像传感器和雷达。

为了实现精准的检测生命体征的各项参数，文献[23]从立体视觉的角度进行处理，利用 RGB-D 摄像头提取深度图像。Chi-chia sun 提出了一种新的基于互补深度图像和颜色信息的快速运动目标检测算法，该算法能够实现精准分割人体面部图像，以达到心率检测的目的。2022 年，Arash Shokouhmand 和 Samuel Eckstrom 开

发了一种相机引导的调频连续波(FMCW)雷达来监测生命体征^[24]，通过红绿蓝深度相机估计人体躯干标志，处理单元不断调整雷达波束以适应受试者的方向。为了不断优化呼吸率和心率监测的感兴趣区域，设计了一种新的基于奇异值的点检测方法^[25]，但是其受光照影响较大，且运算量较高。与此同时，De-Ming Chian 为了应对全球疫情的变化，进一步开发的多人生命体征识别系统，使非接触检测在公共场所可用^[26]。VSign-ID 不仅可以提取多人的生命体征，还可以说明这些生命体征是从谁那里收集的。2022 年，D. Fuentes 利用多个多普勒雷达，以扩大测量区域的有效范围，并提出了一个空间和时间的匹配机制，用于生命体征识别^[27]，使用热感摄像机来检测人数和他们的运动。VSign-ID 有效地协调这两种类型的传感器（即，多普勒雷达和热感摄像机）来跟踪和识别多个人的呼吸率和心跳率^[28]。但是，热感相机精度受环境影响较大，并且在特殊场合存在隐私问题，限制了其应用范围。

1950 年至 1960 年末，雷达技术首次被美国电气工程师 Robert Adler 用于检测人体呼吸和心跳。早期的雷达系统通常使用连续波雷达来测量呼吸和心跳的不同模式^[29]。2000 年以来，MIT 的研究团队开始着手研究 FMCW 雷达的生命体征监测技术，2021 年，这项研究涵盖了多个方面，包括心率监测、呼吸监测以及其他生理参数的监测。

相比之下，雷达在生命体征检测方面的应用展示了其作为一种非接触式监测技术的强大潜力^[30]。它的高度适应性、能够在各种环境条件下工作的能力，以及对目标状态几乎无限制的监测能力，使其在医疗健康监测、安全监控和许多其他领域成为了一个宝贵的工具。其中，调频连续波雷达经常被用于基于发射到移动目标对象和由移动目标对象反射的信号的相位调制的远程生命体征检测。随后，分析这些调制信号以提取关于生命体征的信息^[31]。

通常，用于非接触式生命体征检测的雷达主要包括连续波(CW)雷达、超宽带雷达(Ultra-Wideband, UWB)和调频连续波(FMCW)雷达^[32]。连续波雷达在位移测量方面提供了高精度，但缺乏测距能力，并且容易受到噪声的影响^[33]。超宽带雷达具有距离分辨率高、抗干扰能力强等优点。然而，它在频率利用方面有限制，并且

需要高采样率^[34]。相比之下，FMCW 雷达结合了 CW 雷达和 UWB 雷达的优点。它提供了连续波雷达的灵敏度和 UWB 雷达的测距能力，同时还具有紧凑和轻便的特点。许多现有的工作已经验证了使用 FMCW 雷达进行心率检测的可行性^[35]。在心率检测过程中，影响心率估计精度的主要因素有两个：(1) 滤除心跳信号中的身体运动、身体随机运动引起的干扰、其他干扰和噪声，以及呼吸、心跳信号基波及其谐波和差拍等信号成分。(2) 提升心率估计的精度和鲁棒性。在心率检测过程中必须仔细考虑这些因素。

随着集成电路和雷达技术的发展，雷达被应用于生命体征检测领域，这是雷达技术在医学领域的重要创新。与基于其他硬件的非接触式检测技术相比，基于雷达的非接触式生命体征检测技术具有更强的稳定性和抗干扰能力，同时具备全天候工作能力。此外，基于雷达的检测消除了对用户隐私的担忧。目前，基于雷达的非接触生命体征检测研究主要包括两大类：(1) 优化天线等硬件设备，抑制噪声，提高信号质量。(2) 设计和优化生命体征信号处理中的算法，以提高生命体征检测的准确性和可靠性。

1.3 论文主要工作及结构安排

本课题的主要研究内容是基于深度学习的毫米波雷达实现的心率检测系统，该系统采用 VME 算法，将心跳信号从生命体特征信号中提取出来。在心跳信号状态判别方面，首先利用小波散射网络对心跳信号进行特征提取，然后通过长短期记忆网络进行分类，从而达到判断心跳信号状态的效果。基于心跳信号的状态，通过基于 RLS 的自适应滤波器滤除了心跳信号中的身体运动、身体随机运动引起的干扰、其他干扰和噪声，以及呼吸、心跳信号基波及其谐波和差拍等信号成分。时域上，利用峰-谷差值对自适应滤波后的心跳信号进行心率估计；频域上，利用 CZT 对心率进行估计。最后，利用卡尔曼滤波将时域和频域测得的心率数据相融合，实现了心率值的准确估计。

第 1 章，首先介绍了本文课题的研究背景及意义，并对国内非接触式生命体征

检测的硬件平台和研究现状进行了部分总结。通过对非接触式生命体征检测不同种类的硬件平台比较阐明雷达的优势。通过对于非接触式生命体征现存问题的分析说明本文的研究重点及方向。

第 2 章, 本节讲述了毫米波雷达来检测生命体征的原理。先介绍了 FMCW 雷达是怎么工作的, 然后分析了人体呼吸和心跳信号, 进行了建模工作, 总结了 FMCW 雷达提取这些信号的方法。然后, 文章介绍了经验模态分解(Empirical Modal Decomposition, EMD)算法和变分模态分解(Variational Modal Decomposition, VMD)算法, 并对它们进行了理论推导和仿真。在总结了这些算法之后, 文章提出了采用 VME 算法来解决呼吸和心跳信号模态混叠问题以及计算时间复杂度问题。

第 3 章, 主要介绍了基于小波散射网络-长短期记忆网络模型对心跳信号状态进行判别, 通过小波变换, 小波散射网络能够提供心跳信号在时频域上的特征, 并生成散射特征系数。LSTM 是专门设计用于处理时序数据的递归神经网络。它包含记忆单元和门控机制, 可以捕捉心跳信号中的长期和短期时序依赖关系。小波散射网络提取的时频域特征和 LSTM 学到的时序依赖关系被融合在一起, 形成对心跳信号的综合表示。融合后的表示被送入一个分类器(全连接层)用于对心跳信号的状态进行分类。系统通过监督学习的方式进行训练, 使用带有标签的心跳信号数据集。模型通过最小化损失函数来学习如何正确地分类不同状态的心跳信号。在判断心跳信号处于静止状态或身体微动状态后, 基于 RLS 算法的自适应滤波器选择对应的参考信号, 并使用当前的滤波器权重对输入信号进行线性组合得到预测输出。在迭代更新的过程中, 基于 RLS 算法的自适应滤波器不断更新滤波器权重与协方差矩阵, 以适应输入信号的变化, 从而达到滤除包含了身体运动、身体随机运动引起的干扰、其他干扰和噪声, 以及呼吸、心跳信号基波及其谐波和差拍等信号成分。并且通过参考信号的选择、滤波器权重与协方差矩阵的更新, 从而抑制干扰信号, 获得更加纯净和更准确的心跳信号。

第 4 章, 本章介绍了一种名为 KFTF(Kalman Filter with Time-Frequency Domain

Fusion)的心率估计方法,该方法通过卡尔曼滤波与时频域融合技术相结合,旨在提高心率估计的准确性和稳定性。具体而言,该方法首先对经过自适应滤波的心跳信号进行峰-谷差值去噪,以实现初步的心率估计。在频域方面,利用 CZT 技术提高心率信号的估计精度。最后,通过卡尔曼滤波过程,将时域心率估计与频域心率估计相融合,从而更全面地提高心率估计的精准性和稳健性。该方法的独特之处在于充分利用了时域和频域信息,并通过卡尔曼滤波进行有效融合,弥补了传统心率估计方法在面对随机干扰时的不足,相较于单一维度的心率估计方法,鲁棒性及精度均有较大提升。通过这种不同维度的数据融合方式,KFTF 方法能够更可靠地估计心率。

第 5 章,本章将以上所使用的雷达信号预处理流程、VME 算法、小波散射网络-长短期记忆网络、基于 RLS 的自适应滤波、以及 KFTF 心率估计方法相结合,形成了一个完整的基于毫米波 FMCW 雷达的非接触式心率检测方案。通过讲述雷达设备、实验设置来进行方案可行性的验证,表明所提方案的有效性和优越性

第 6 章,总结和展望,本文在基于毫米波雷达的生命体征检测理论研究方面做出了重要贡献。文章的创新之处在于深度学习技术应用于生命体征检测,并结合了多种信号处理算法来提取呼吸和心跳信号,创新性的利用数据融合的方法,将多维度的心率估计值进行融合,提高了心率估计值的精度和鲁棒性。然而,本文也存在一些不足之处。首先,深度学习训练所使用的数据库较小,并不完善,需要进一步的丰富相关数据。其次,针对算法的可扩展性和实用性还需要进一步的研究和验证。未来,可以进一步改进算法,提高其对复杂环境和实时性的适应能力。

2 毫米波雷达生命体征检测理论研究

本文采用的是基于 FMCW 体制下的毫米波雷达，因此先介绍了 FMCW 雷达是如何工作的，然后对生命体征信号进行建模分析，说明呼吸谐波、身体运动、身体随机运动及交调信号对心率检测的影响^[36]。介绍了 FMCW 毫米波雷达的生命体征提取算法，并对 EMD、VMD 和 VME 等算法进行分析和仿真，通过对于信噪比及运算速度的比较，说明为何采用 VME 算法将心跳信号从生命体征信号中提取出来。

2.1 FMCW 雷达目标检测原理

FMCW 雷达全称是调频连续波雷达(Frequency Modulated Continuous Wave Radar)，主要有线性调频(Linear FMCW)和非线性调频(Nonlinear FMCW)两种类型^[37]，这里我们使用的是线性调频连续波雷达。

2.1.1 锯齿波 FMCW 信号分析

FMCW 雷达系统中的目标检测回波信号依赖于发射到雷达视场中的调频信号的波形，图 2-1 展示了锯齿波调频连续波：




图 2-1 锯齿波调频连续波发射及接收信号的频域波形

其中， f_{\min} 为 FMCW 信号起始频率， B 表示带宽， T_d 是时宽， $K = B/T_d$ 是频率斜率。黑线代表发射信号的瞬时频率变化，黄线代表回波信号的瞬时频率变化，

$t_d = 2R/c$ 为回波延时(R 是目标距离, c 为光速)^[38]。

每个周期的 chirp 信号可以表示为:

$$x_T(t) = A_T(2\pi f_{\min}t + \pi \frac{B}{T_d}t^2 + \phi(t)) \quad (2-1)$$

式中, $t \in [-T/2, T/2]$, A_T 是幅度 $\phi(t)$ 发射机的相位噪声。

在该信号的照射下, 距离 R 点处的点目标所产生的雷达回波信号可以被视为发射信号经过幅度衰减和时间延迟后的结果, 雷达接收信号瞬时频率如图 2-1 所示。

如果回波信号的幅度被衰减到 A_R , 则回波信号的表达式可以由式(2-1)获得:

$$\begin{aligned} x_R(t, \tau) &= \frac{A_R}{A_T} x_T(t - \frac{2d(\tau)}{c}) \\ &= A_R(2\pi f_{\min}(t - \frac{2d(\tau)}{c}) + \pi \frac{B}{T_d}(t - \frac{2d(\tau)}{c})^2 + \phi(t - \frac{2d(\tau)}{c})) \end{aligned} \quad (2-2)$$

其中, τ 是一个独立的时间变量, 用来区分雷达参考信号和目标运动的时变状态, 当目标运动时, 到目标的距离将随着 τ 的不同值而变化。因此, τ 是运动目标检测的关键参数, 与雷达信号相比, 式(2-2)中包含的目标信息具有低速、时变的特点。为了增强目标运动的信息, 我们将他们进行混频, 因此, 中频信号可以表示为:

$$x_{IF}(t, \tau) = A_R \exp(j \cdot (4\pi \frac{Bd(\tau)}{cT_d}t + 4\pi \frac{f_{\min}d(\tau)}{c} + 4\pi \frac{d^2(\tau)B}{c^2T_d} + \Delta\phi)) \quad (2-3)$$

其中, $\Delta\phi$ 为残余相位, 在相干系统中通常可以忽略。因此, 此高阶小量在式(2-3)中被忽略。因此, 可以简化为:

$$x_{IF}(t, \tau) = A_R \exp(j \cdot (2\pi f_b(\tau)t + 4\pi \frac{d(\tau)}{\lambda_c})) \quad (2-4)$$

其中, $\lambda_c = c/f_c$, $f_b(\tau) = 2Bd(\tau)/cT_d$ 。为了简化上述过程, 忽略了热噪声和其他干扰。 $f_b(\tau)$ 为时间相位, $d(\tau)$ 为空间相位^[39]。

2.1.2 中频信号的相位对胸腔运动的敏感性

当雷达与目标之间的距离变化时，空间变化更加显著，因此，空间相位用于表示轻微震动目标的距离波动。采用快速傅里叶变换将空间相位与时间相位分离得到 $X_{IF}(f, \tau)$ 为：

$$X_{IF}(f, \tau) = A(f, \tau) \exp(j \cdot 4\pi \frac{d(\tau)}{\lambda_c}) \quad (2-5)$$

其中，频谱域信号幅度 $A(f, \tau)$ 可以表示为以下 $\sin c$ 函数：

$$A(f, \tau) = A_R T_d \sin c(T_d(f - f_b(\tau))) \quad (2-6)$$

其中， T_d 是一个 chirp 的观察时间。

根据 $\sin c$ 函数的特性，频谱信号幅度在 $f_m = f_b(\tau)$ 处达到其最大值。随后，可以在相应的频率中进一步提取空间相位。

对于静止目标，所获得的空间相位不随 τ 而变化，对于运动目标，空间相位受 τ 的变化影响，这可以进一步提供关于时谐运动引起的目标的振动频率关系，其由 $d(\tau)$ 和 τ 的关系确定。因此，利用这一原理，可以实现雷达生命体征检测的应用。

2.2 雷达信号预处理

本节介绍距离维 FFT-静态杂波滤除-距离单元选取-相位解缠的回波信号预处理算法，利用静态杂波滤除算法滤除环境杂波，消除直流分量，然后通过 FFT 定位人体距离窗，提取相位信息并解卷绕，得到生命体征相位信息。预处理流程如图 2-2：

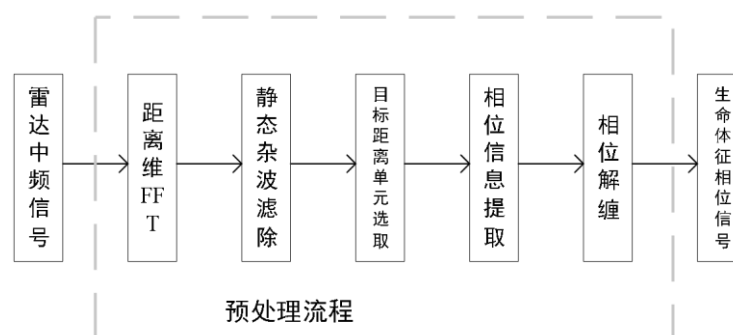


图 2-2 雷达信号预处理流程

2.2.1 距离维 FFT

对预处理后的信号进行距离维 FFT 变换, 将时域信号转换为距离域数据, 得到距离和信号强度之间的关系^[40]。

将雷达回波信号 $x_R(t, \tau)$ 视为静止目标回波信号 $x_{RS}(t, \tau)$ 和运动参考信号的回波信号 $x_{RM}(t, \tau)$, 可得:

$$x_R(t, \tau) = x_{RS}(t, \tau) + x_{RM}(t, \tau) \quad (2-7)$$

假设环境中存在 L 个静止目标和 I 个运动目标, 则 $x_{RS}(t, \tau)$ 和 $x_{RM}(t, \tau)$ 为:

$$x_{RS}(t, \tau) = \sum_{l=1}^L A_{Rl} \cos((2\pi f_{\min}(t - \frac{2d_l}{c}) + \pi \frac{B}{T_d}(t - \frac{2d_l}{c})^2 + \phi_l(t - \frac{2d_l}{c}))) \quad (2-8)$$

$$x_{RM}(t, \tau) = \sum_{i=1}^I A_{Ri} \cos((2\pi f_{\min}(t - \frac{2d_i}{c}) + \pi \frac{B}{T_d}(t - \frac{2d_i}{c})^2 + \phi_i(t - \frac{2d_i}{c}))) \quad (2-9)$$

混频后可得 $x_{IF}(t, \tau)$:

$$x_{IF}(t, \tau) = \sum_{l=1}^L A_{Rl} \exp(j \cdot (2\pi f_{bl}t + 4\pi \frac{f_{\min}d_l}{c})) + \sum_{i=1}^I A_{Ri} \exp(j \cdot (2\pi f_{bi}t + 4\pi \frac{f_{\min}d_i}{c})) \quad (2-10)$$

在时间轴 t 上进行分离目标空间相位。频谱域信号可以表示为:

$$X_{IF}(f, \tau) = \sum_{l=1}^L A_{Rl} T_0 \exp(j \cdot \phi_l) \sin c(T_0(f - f_{bl})) + \sum_{i=1}^I A_{Ri} T_0 \exp(j \cdot \phi_i(\tau)) \sin c(T_0(f - f_{bi}(\tau))) \quad (2-11)$$

其中, $\phi_l = 4\pi d_l / \lambda_c$, $\phi_i = 4\pi d_i / \lambda_c$ 。

对式(2-11)进行频谱搜索来提取每个目标的距离信息, 将频谱数据从快时间维度转换到距离维度上。在这个过程中, 首先对接收到的信号进行快时间维上的 FFT 变换, 将信号转换到频率域。然后, 通过雷达系统的特性和目标的运动状态, 将频谱数据与距离之间建立起对应关系, 进而将频谱数据转换为距离域表示。这样做的目的是将信号从时间-频率的表示转换为距离-频率的表示。




图 2-3 单 chirp 数据的距离维 FFT 结果

图 2-3 生动地描绘了对某个 chirp 信号执行 M 点快速傅里叶变换(FFT)的场景。雷达发射 chirp 数为 N ，每个 chirp 的采样点数为 M ，相应的回波信号按列写入信号存储器，这样就会形成 $M * N$ 的原始 AD 数据矩阵。为了确定人体所在位置，我们需要对原始 AD 数据矩阵进行 Range-FFT，即对数据矩阵的每一列进行 M 维的 FFT，得到 M 个距离单元。矩阵中同一行的每个采样点到雷达的距离是相同的，故一行称为一个距离单元。矩阵的水平坐标表示时间维度，即慢时间维度；纵坐标表示距离维度，即快时间维度。一旦确定了雷达模块及其配置参数，每个距离单元所代表的距离固定不变。

2.2.2 静态杂波滤除

对于雷达生命体征检测的实际应用，雷达视场中可能包含除人体目标之外的各种静止目标。在心率测量的应用中，这些环境目标往往被视为强杂波干扰，此外在人体产生的雷达回波中，心跳信息仅存在于胸壁目标回波之中，胸壁的运动是呼吸和心跳运动的叠加，这种强杂波干扰会使胸壁的微弱运动不明显。因此，需要去除这些环境目标和背景噪声^[41]。

相量均值相消算法的核心思想是求取所有回波 chirp 的相位均值，并将这个均值从每个回波 chirp 中减去，以消除静态杂波的影响。这样一来，静态杂波被有效

地抑制，从而保留了微动目标的相位和幅值信息，有利于微动目标的检测。

在本研究中，相量均值相消算法将被添加在距离维 FFT 之后。在应用相量均值相消算法之后，杂波被抑制，已知：

$$X_{IF}(f, \tau) = I(f, \tau) + jQ(f, \tau) \quad (2-12)$$

$$\begin{aligned} I(f, \tau) &= \text{real}(X_{IF}(f, \tau)) \\ Q(f, \tau) &= \text{imag}(X_{IF}(f, \tau)) \end{aligned} \quad (2-13)$$

计算式(2-11)中 τ 的平均值，则结果主要来自于每个静止目标，这一特性使我们能够有效地过滤强平稳杂波干扰。假设 τ 被采样，则存在总共 M 个采样点，平均值 $X_{dc}(f)$ 为：

$$X_{dc}(f) = \frac{\sum_{m=1}^M I(f, \tau_m)}{M} + j \frac{\sum_{m=1}^M Q(f, \tau_m)}{M} \quad (2-14)$$

其中， $\tau_m = mt_s$ ， t_s 为采样间隔。

向量均值相消算法可由 $\bar{X}_H(f, \tau) = X_{IF}(f, \tau) - X_{dc}(f)$ ，可进一步写为：

$$\bar{X}_H(f, \tau) = \sum_{i=1}^I A_{Ri}(f, \tau) \exp(j\phi_i(\tau)) - X_{dc}(f_i) \quad (2-15)$$

其中， $A_{Ri}(f, \tau) = A_{Ri} T_d \sin c(T_d(f - f_{bi}(\tau)))$ 。

图 2-4 显示了采用和不采用相量均值相消算法的静态杂波抑制算法后生成的距离维 FFT 的结果。可以清楚的看出，图 2-4(a)在没有静态杂波抑制的情况下，背景噪声较大，1.5m 处存在较大的峰值，会使参考信号难以被正常识别和提取，降低了对生命体征参数的测量精度和准确性。图 2-4(b)展现了应用向量平均相消法去除静态杂音后的效果。处理之后，背景噪声滤除的异常干净，而且，参考信号的强度没有受到减弱。因此本研究采用相量均值相消算法来抑制静态杂波，同时能更好的保留人体行为的微多普勒信息，提升后续信号处理的性能。

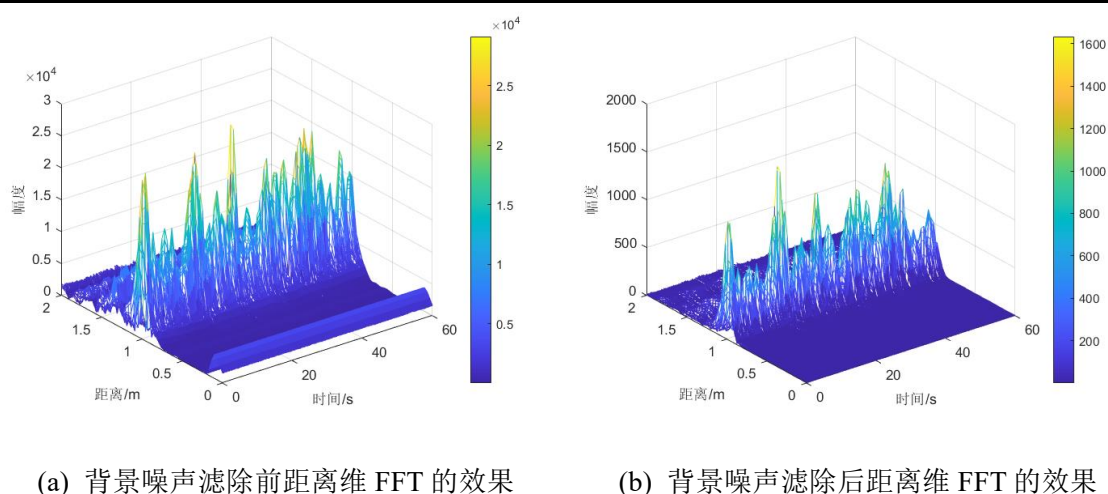



图 2-4 背景噪声滤除前后的距离维 FFT 对比

2.2.3 目标人体所在距离单元选择

在实验设置中，人体处于静止状态下，由胸腔带来的微动并不会发生距离单元的改变，而运动状态下，人体会由较大幅度身体摆动，胸腔的微动信息所在的距离单元会发生改变，如果距离单元信息不随着人体运动发生改变，那样将无法获得准确的生命体征信息^[42]。

毫米波雷达接收到目标物体反射回来的信号，通过分析接收到的信号频谱，可以测量到多普勒频移，这个频移告诉了我们目标物体相对于雷达系统的速度信息。毫米波雷达具有高频特性，可以更精确地测量目标物体的速度。因此，可以利用目标物体的速度信息和雷达之前的距离测量结果来推断目标物体在下一个时刻的位置。结合多普勒频移测量和速度-距离关系，可以对目标物体所在的距离单元进行更新。如果目标物体在运动，其位置会在下一个时刻发生变化。根据多普勒频移测量得到的速度信息，可以预测目标物体在下一个时刻的位置。然后，根据预测的位置信息，可以更新目标物体所在的距离单元。更新后的距离单元可以根据雷达系统的分辨率和目标物体的位置来确定。根据目标物体的预测位置以及雷达系统的参数，选择最合适的距离单元来表示目标物体的位置。



(a) 静止状态时距离维 FFT 的结果

(b) 身体运动时距离维 FFT 的结果

图 2-5 不同状态下距离维 FFT 的结果

图 2-5(a)展示了静止人体目标的距离维 FFT 结果，而图 2-5(b)展示了包含身体随机运动的距离维 FFT 结果。从图 2-5(a)可以观察到，在 60 秒的检测过程中，被测人体目标处于静止状态时，其所处的距离单元保持不变。这表明目标的位置在整个检测过程中保持不变，因此距离维 FFT 的结果呈现出稳定的特征。相比之下，从图 2-5(b)可以看出，当被测者在检测过程中存在身体运动时，其距离单元会发生变化。这表明目标的位置在检测过程中发生了变化，可能是由于人体的呼吸、心跳或其他运动引起的。这种运动会导致目标在距离维度上的位置发生变化，从而在距离维 FFT 结果中呈现出不同的特征。通过比较图 2-5(a)和图 2-5(b)，可以清晰地观察到静止人体目标和运动人体目标在距离维 FFT 结果中的差异，这也是我们进行距离单元选择的原因。

2.2.4 相位解缠

一旦确定了目标所在的距离单元，就可以对该距离单元内的相位信息进行提取。距离维 FFT 的结果使用复信号表示，其中 I(In-phase)和 Q(Quadrature)两路信号具有正交特性。针对目标所在的距离门，可以使用反正切函数来提取目标的相位，从而得到其随时间变化的幅度。图 2-7(a)显示了相位随时间变化的幅度。

假设 t_1 时刻相位为 -100° ， t_2 时刻相位为 -225° ，如图 2-6 所示，是用反正切函数，则在 t_2 时刻输出的值为 135° ，相比 -225° 发生了 2π 的相位跳动，这是因为

angle 里面使用的正切周期函数为 2π ，并且具有角度范围，即 $[-\pi, \pi]$ ，但示意图中相位变化范围为 $[-2\pi, 2\pi]$ ，在 $\pm\pi$ 处会发生突变。





图 2-6 目标相位随时间变化坐标示意图

为了修正相位值，当相邻两时刻的相位差值大于 π ，或者小于 $-\pi$ 的时候，需要对后一个时刻相位值进行 $\pm 2\pi$ 的操作。值得注意的是，如果相邻两时刻之间真实相位差没有超过 π 进行了加减操作，会发现相位失真。这种相位的补偿操作，被称为相位解缠。

解缠前后的相位随时间变化对比如图 2-7 所示，相位解缠后，从雷达接收到的信号可能会更清晰，因为相位解缠可以帮助去除来自杂波干扰，从而提高了信号的质量。相位解缠后，可以更准确地提取心跳信号。通过分离雷达信号中的运动信息和其他噪声，相位解缠可以更精确地捕捉到心脏搏动引起的微小相位变化：



(a) 相位解缠前的相位图

(b) 相位解缠后的相位图

图 2-7 相位解缠前后相位图

2.3 生命体征信号建模

生命体征信号建模是指对人体产生的生理信号进行数学建模的过程，这种建模可以帮助理解生命体征信号的特性，提取有用的信息以及设计相关的信号处理算法。一般来说，人体呼吸和心跳的幅度和频率如表 2-1 所示。

表 2-1 人体生命体征信号幅度频率参考值

生命体征信号	频率(Hz)	幅度(mm)
呼吸信息	0.1–0.6	1–12
心跳信息	0.8–2.0	0.1–0.5

当人体相对雷达处于静止位置时，可以对生命体征信号进行建模。以下是对生命体征信号的简要建模：


$$\begin{aligned} R_B(t) &= r_1 \sin(2\pi w_1 t) \\ R_H(t) &= r_2 \sin(2\pi w_2 t + \theta) \end{aligned} \quad (2-16)$$

其中， r_1 为呼吸振动幅度， w_1 为呼吸频率。同样， r_2 为心跳振动幅度， w_2 为心跳频率， θ 为心跳与呼吸之间的相位差。

在现实场景中，建模生命体征信号时需注意到呼吸信号及其谐波与心率信号谐波的相互作用。这意味着生命体征信号可以被理解为多个正弦波信号的组合，每个正弦波分别代表着不同频率的谐波成份。这种建模方法可以更准确地描述生命体征信号的频谱特性，为后续的信号处理和分析提供更精确的基础：

$$R(t) \approx R_0 + r_1 \sin(2\pi w_1 t) + r_2 \sin(2\pi w_2 t + \theta) \quad (2-17)$$

图 2-8(a)为理想条件下生命体征信号模型图，根据式(2-16)设置相关参数。呼吸频率 $w_1 = 0.25\text{Hz}$ ，心跳频率 $w_2 = 1\text{Hz}$ ；呼吸信号幅度 $r_1 = 2.5\text{mm}$ ，心跳信号幅度为 $r_2 = 0.25\text{mm}$ 。通过图 2-8(b)中生命体征信号的频谱图，可以得出呼吸为 20 次/分钟，心跳为 60 次/分钟。



(a) 理想条件下生命体征信号模型

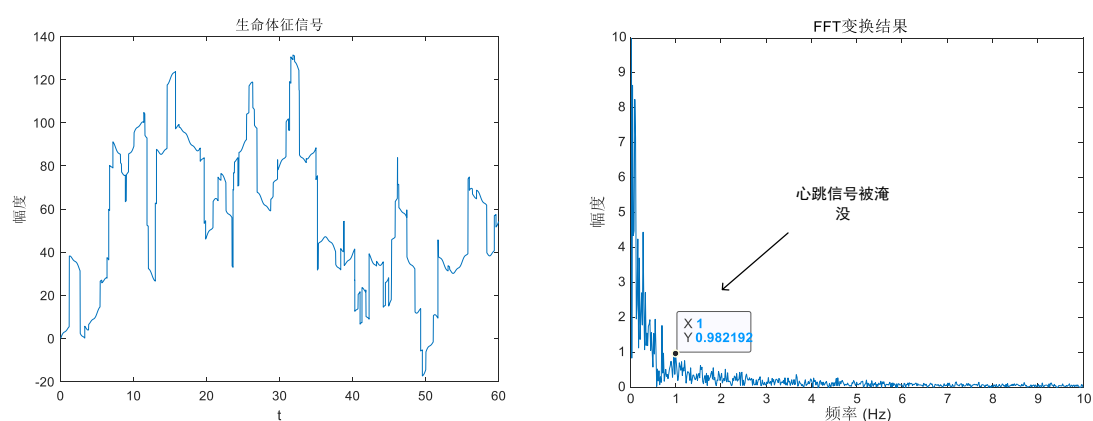
(b) 理想条件下生命体征信号频谱图

图 2-8 生命体征信号模型及其频谱图

在检测呼吸和心率的过程中，会存在相应的噪声干扰，所以需要在信号上加上噪声。而且心跳信号的幅度很小，呼吸的二次谐波及三次谐波给心跳信号带来较大的影响，可能会干扰正常心跳频率的判定。同样，当人体处于被监测的状态下，会出现身体的随机运动，我们把它们归类为人体目标面向或远离雷达检测系统的短时间运动。考虑到这种情况，文献[43]能够较好地描述身体运动信号在时域上的特征，其中随机峰值的幅度和持续时长使得模型能够适应不同类型和强度的运动：

$$B(t) = \begin{cases} A_1 - A_2 \times 2|t - T_1/2|/T_1 \leq T_1 \\ A_2 - A_2 \times 2|t - T_2/2 - T_1|/T_2, T_1 \leq t \leq T_1 + T_2 \\ \dots \\ A_n - A_n \times |t - T_n/2 - T_1 - \dots - T_{n-1}|, T_1 + \dots + T_{n-1} \leq t \leq T_1 + \dots + T_n \\ 0, \text{其他} \end{cases} \quad (2-18)$$

其中， n 表示存在身体运动的时间单元的总数目， A_1, A_2, \dots, A_n 表示这 n 个三角波的幅度， T_1, T_2, \dots, T_n 表示这 n 个三角波的持续时长。



(a) 存在身体运动时生命体征信号 (b) 存在身体运动时生命体征信号频谱图
图 2-9 存在身体运动及呼吸谐波等干扰的生命体征信号模型及其频谱图

图 2-9 是包含身体运动及呼吸和心跳信号谐波等干扰的生命体征信号模型及其频谱,可以看出,在呼吸信号和心跳信号的检测中,由于它们在频率和幅度上的相似性,以及存在的噪声干扰和雷达器件自身干扰,确实会面临一定的挑战。呼吸信号和心跳信号在振幅上存在较大的差异,这会导致心跳信号很容易被呼吸信号的幅度所淹没。同时,呼吸信号的谐波频率与心跳信号的频率接近,这会导致频谱上的重叠,使得两者难以分离。身体运动也会极大的影响心跳信号,导致心跳信号淹没在不规则的身体运动之中。由此可见,提取出干净的心跳信号分量是一项不小的挑战。

2.4 模态分解类算法

在人体处于不同状态下,如运动、呼吸深度变化等情况下,心跳信号很容易受到身体运动、身体随机运动引起的干扰、其他干扰和噪声,以及呼吸、心跳信号基波及其谐波和差拍等信号成分的影响,这对心率测量的准确性产生影响。因此,寻找合适的算法来分离生命体征信号并有效抽取心跳信息,对于实现精确的心率测定至关重要。

2.4.1 EMD 算法及仿真分析

经验模态分解算法(EMD)基于瞬时频率、本征模态函数的概念,能够将信号分

解为若干个 IMF 分量，每个 IMF 表征信号的局部特征。生命体征信号通常是非平稳信号，具有复杂的时频特性，因此采用模态分解类算法在生命检测领域是可行的

[44]。

EMD 分解的具体步骤为::

步骤一：根据待分解信号的极大值确定上包络线，极小值确定下包络线。

步骤二：根据上下包络线计算均值包络线。

步骤三：将待分解信号减去均值包络线，得到中间信号。

步骤四：判断中间信号是否满足 IMF 分量的两个约束条件。如果符合两个约束条件，当前得到的中间信号就为一个 IMF 分量；如果不符合，则将当前的中间信号作为新的待分解信号，循环执行步骤二到步骤四。

步骤五：若当前中间信号满足两个约束条件，用当前的待分解信号减去当前得到的 IMF 分量，得到当前的残余项。然后判断残余项是否为单调函数。如果是单调函数，则 EMD 分解结束；否则将当前的残余项作为待分解信号，仍继续进行步骤一到步骤四的迭代，直到满足终止条件为止。

通过以上过程，可以将任何信号分解为以下形式：

$$x(t) = \sum_{i=1}^n h_i(t) + r_n(t) \quad (2-19)$$

即 n 个 IMF 分量与一个残差分量之后的形式。

从心率数据库随机选取一段毫米波雷达检测得到的生命体征信号，通过 EMD 算法进行分解，得到的结果如图 2-10 所示：




图 2-10 经 EMD 算法对实测信号分解的各模态分量时域波形图

从图 2-10 可以观察到, 使用 EMD 算法对实测信号进行分解后, 得到的独立模态函数(IMF)分量的时间尺度错位。具体来说, 图中 IMF4 和 IMF5 分量显示出相同的时间尺度。同一个频率成分可能被分解到不同的模态中, 或者多个频率成分被分解到同一个模态中, 使得对信号频率特征的解释和分析变得困难。此外, EMD 算法分解得到的模态之间可能存在耦合关系, 即不同模态之间可能相互影响, 难以完全独立地描述信号的特征。这可能导致在后续分析中难以对模态进行准确的解释和利用。

2.4.2 VMD 算法及仿真分析

变分模态分解(Variational Mode Decomposition, VMD)是一种用于信号分解的自适应算法, 它能够将信号分解成多个局部频率和振幅调制的本征模态函数。VMD 算法通过交替最小化目标函数的方式, 实现了对信号的自适应分解, 从而描述信号的时频特性和局部特征^[45]。

VMD 算法的核心是通过优化一个目标函数来实现信号的分解, 该目标函数分为两部分组成: 数据拟合项和正则化项。优化目标函数可以表示为:

$$\begin{aligned} \min_{\{\mu_k(t)\}, \{w_k\}} & \left\{ \sum_{k=1}^K \left\| \partial_t \left[(\delta(t) + \frac{j}{\pi t}) * u_k(t) \right] e^{-jw_k t} \right\|_2^2 \right\} \\ \text{s.t.} & \sum_k u_k(t) = x(t) \end{aligned} \quad (2-20)$$

其中, $u_k(t)$ 为第 K 个模态分量, w_k 为第 K 个模态分量的中心频率, $\delta(t)$ 为 Dirac 分布。

为找到上述问题的最优解, 引入二次惩罚项 α 和拉格朗日乘子 λ , 构造增广 Lagrangian 函数 $L(\{u_k\}, \{w_k\}, \lambda)$:

$$= \alpha \sum_k \left\| \partial_t \left[(\delta(t) + \frac{j}{\pi t}) * u_k(t) \right] e^{-jw_k t} \right\|_2^2 + \left\| x(t) - \sum_k u_k(t) \right\|_2^2 + \langle \lambda(t), x(t) - \sum_k u_k(t) \rangle \quad (2-21)$$

在交替向量乘子(ADMM)框架下, VMD 算法在频域空间中交替更新迭代, 其中, 模态分量、频率权重和拉格朗日乘子不断地进行更新。ADMM 算法通过引入辅助变量和拉格朗日乘子, 将原始问题转化为一系列子问题, 利用交替迭代的方式求解原始问题的解。在频域空间交替更新迭代后的模态分量、中心频率以及拉格朗日乘子的表达式如下:

$$\begin{cases} \hat{u}_k^{n+1}(w) = \frac{\hat{x}(w) - \sum_{i \neq k} \hat{u}_i^n(w) + \hat{\lambda}^n(w)/2}{1 + 2\alpha(w - w_k)^2} \\ w_k^{n+1} = \frac{\int_0^\infty w |\hat{u}_k(w)|^2 dw}{\int_0^\infty |\hat{u}_k(w)|^2 dw} \\ \hat{\lambda}^{n+1}(w) = \hat{\lambda}^n(w) + \tau(x(w) - \sum_k \hat{u}_k^{n+1}(w)) \end{cases} \quad (2-22)$$

其中, $\hat{u}(w)$, $\hat{x}(w)$ 和 $\hat{\lambda}(w)$ 分别是 $u_k(t)$, $x(t)$ 和 $\lambda(t)$ 的傅里叶变换, n 为迭代次数; τ 为噪声容限。

当满足以下条件时终止迭代:

$$\frac{\sum_k \|\hat{u}_k^{n+1} - \hat{u}_k^n\|_2^2}{\sum_k \|\hat{u}_k^n\|_2^2} < \varepsilon \quad (2-23)$$

VMD 算法可以总结为以下步骤:

Step1. 初始化参数 $\{\hat{u}_k^1\}$, $\{\hat{w}_k^1\}$, $\hat{\lambda}^1$, n , $\tau = 0$, $\varepsilon = 1 \times 10^{-7}$ 。

Step2. 根据式(2-22)迭代 $\hat{u}(w)$, $\hat{x}(w)$ 和 $\hat{\lambda}(w)$ 。

Step3. 重复 Step1~Step2, 若满足式(2-23), 停止迭代并输出 K 个 IMF 分量。

为了验证 VMD 的分解效果, 通过毫米波雷达对人体进行检测得到生命体征信号, 进行 VMD 分解, 得到的时域波形和对应的频域图如下图 2-11:

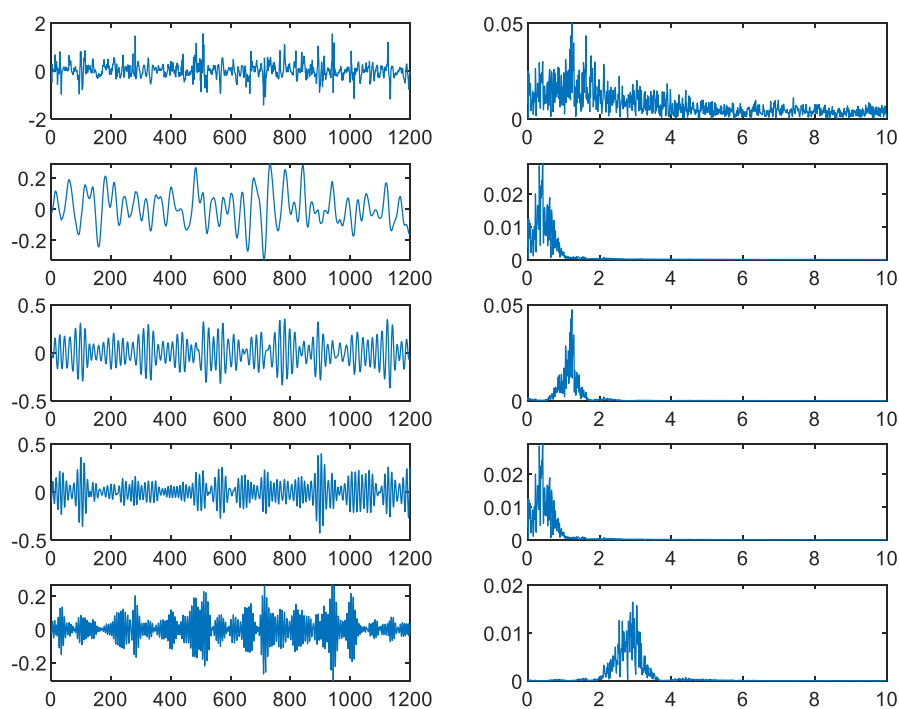


图 2-11 经 VMD 分解后的各模态分量时域波形图及对应频谱图

该函数需要人为确定的输入输出参数较多, 且 K 和 α 对分解结果影响较大。例如设定的 K 值小于所需分解模态数, 模态混叠。如果设定的 K 值远大于所需分解模态数, 会出现无效的虚假分量。同时 VMD 算法运算量较大, 难以做到对信号实时分析。

2.4.3 VME 算法及仿真分析

VME 算法通过引入先验的频率分布范围，自适应地选择合适的频率范围，并通过改进的模式提取过程，更有效地提取特定模式的信号，有助于在呼吸信号和心跳信号提取等领域中应用^[46]。其算法具体步骤为：

步骤一：初始化相关参数 $\hat{\lambda}_1$, \hat{u}_d^1 , w_d^1 , n 。其中， \hat{u}_d^1 是期望提取到的模态分量， w_d^1 是期望的目标模态的中心频率。

步骤二：令 $n = n + 1$ ，并循环。

步骤三：对所有的 $w \geq 0$ ，根据式(2-24)不断更新 \hat{u}_d

$$\hat{u}_d^{n+1}(w) = \frac{\hat{f}(w) + \alpha^2(w - w_d^{n+1})^4 \hat{u}_d^n(w) + \frac{\hat{\lambda}(w)}{2}}{[1 + \alpha^2(w - w_d^{n+1})^4][1 + 2\alpha(w - w_d^n)^2]} \quad (2-24)$$

步骤四：根据式(2-25)不断更新 w_d

$$w_d^{n+1} = \frac{\int_0^\infty w |\hat{u}_d^{n+1}(w)|^2 dw}{\int_0^\infty |\hat{u}_d^{n+1}(w)|^2 dw} \quad (2-25)$$

步骤五：当 $w \geq 0$ ，更新拉格朗日乘子 $\hat{\lambda}$

$$\hat{\lambda}^{n+1} = \hat{\lambda}^n + \tau \left[\frac{\hat{f}(w) - \hat{u}_d^{n+1}(w)}{1 + \alpha^2(w - w_d^{n+1})^4} \right] \quad (2-26)$$

步骤六：判断是否满足收敛条件：

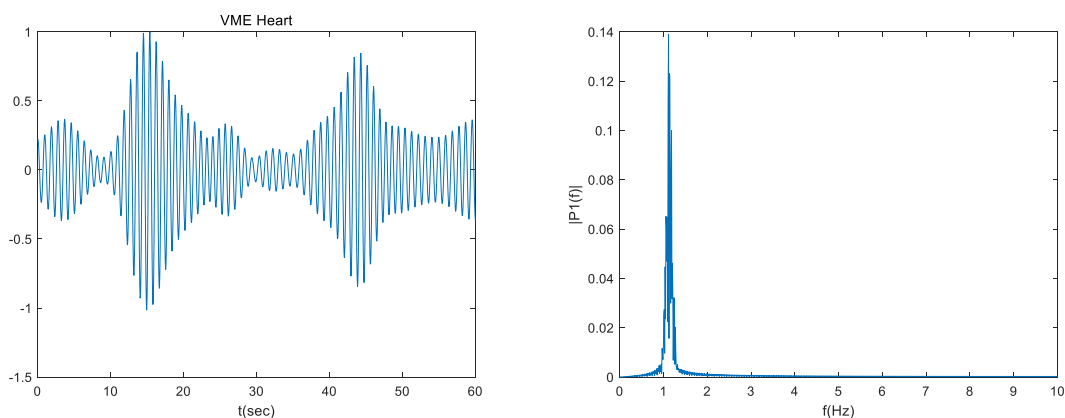
$$\frac{\|\hat{u}_d^{n+1} - \hat{u}_d^n\|_2^2}{\|\hat{u}_d^n\|_2^2} < \varepsilon \quad (2-27)$$

如果满足收敛条件，算法终止。如果不满足收敛条件，回到步骤二，继续迭代优化，直到满足收敛条件为止。

VME 算法根据先验的频率分布范围提供了关于特定模式信号的先验知识。根

据先验的频率范围，VME 算法针对特定模式的信号提供了先验的频率分布范围，使得信号分解更具针对性和准确性。根据先验的频率范围，VME 算法能够自适应地选择合适的频率范围，适应不同模式信号的特点，提高了算法的适用性和稳定性。VME 算法通过改进的模式提取过程，能够更有效地提取特定模式的信号成分，提高了信号分解的精度和准确性。VME 算法在生物医学信号处理等领域具有广泛的应用前景，可以用于呼吸信号、心跳信号等特定模式信号的提取和分析。

使用 VME 算法对实测信号进行仿真并对其做快速傅里叶变换，结果如下图 2-12 所示：



(a) 经 VME 提取出来的心跳信号波形图 (b) 经 VME 提取出来的心跳信号频谱图

图 2-12 经 VME 提取出来的心跳信号波形图及对应频谱图

VME 算法通过先验频率范围的提供和改进的模式提取过程，能够更有效地提取特定模式的信号，具有较高的准确性和适用性，在生物医学信号处理等领域具有重要的应用价值。

2.5 算法性能分析

为了选择一个合适的模态分解类算法提取出心跳信号，我们对以上三种常用的模态分解类算法进行比较。然后通过信噪比和运行时间对不同模态分解类算法进行分析，模态分解类的算法优缺点如表 2-2。

表 2-2 模态分解类算法优缺点对比

算法	EMD 算法	VMD 算法	VME 算法
优点	算法计算复杂度低、在经验模态分解类算法中较低	完全非递归算法、运行时间较经验模态分解类提升较大	针对特定的频率分量进行提取，大大简化了运算复杂度
缺点	存在端点效应、模态混叠等问题	需要预先设定分解个数、惩罚因子等相关参数，影响较大	算法的频率估计受到选取频率的影响

由表 2-2 可知，经验模态类算法存在端点效应、模态混叠、噪声残留、虚假分量等问题，并且运算复杂、运行时间长。而变分模态分解类算法中 VME 很好的解决了这些问题。由于 VME 算法是一种非递归算法，可以提取特定频率分量，大大减少算法自身的复杂度，运算时间大幅降低。并且该算法可以提取特定的频率分量，提取的频率在频谱中占据主导地位，故该算法分离出的心跳信号的信噪比很高，适用于将心跳信号从生命体征信号中分离出来。

2.5.1 信噪比分析

信噪比(SNR)衡量信号质量的重要指标之一。高信噪比表示信号相对于噪声更强，有助于提高生命体征检测系统的性能和可靠性。信噪比的提高可以增强生命体征检测系统的灵敏度和特异性^[47]。对于生命体征信号，如心跳信号或呼吸信号，较高的信噪比可以提高系统对细微变化的响应能力，同时降低了误报率。本文采用功率信噪比，计算公式如下：

$$SNR = 10 \lg \left(\frac{\sum_{n=-5}^5 s^2(l+n)}{\sum s^2(f) - \sum_{n=-5}^5 s^2(l+n)} \right) \quad (2-28)$$

其中， $s^2(l)$ 为最高频谱峰值的功率。本文我们选取频谱最高峰值即最高峰左右各 5 个峰值的功率作为有用信号功率。

我们选取了 20 次实测数据，分别经 EMD、VMD、VME 分解算法，计算其信

噪比，并求其均值，结果如表 2-3 所示。

表 2-3 实测信号分离的心跳信号的信噪比

模态分解算法	EMD 算法	VMD 算法	VME 算法
信噪比	-5.67	6.98	11.78

从表 2-3 中可以观察到，VME 算法分离出的心跳信号的信噪比相对于 EMD 算法和 VMD 算法分别提高了 17.45dB 和 4.8dB。这表明，相比于 EMD 算法和 VMD 算法，VME 算法在分离信号的信噪比方面具有显著的优势。这种优势为 VME 算法带来了更广泛的应用前景。高信噪比的信号对于后续的信号处理和分析至关重要，因为它们能够提供更清晰、更可靠的生物体征信息，从而更有效地识别和监测目标生理状态。

2.5.2 运行时间分析

我们通过计算运行时间来评估各模态分解算法的性能，本文使用的机器设备为 Dell G 系列笔记本，处理器为 AMD Ryzen 5 4600H(六核，12 线程，基频 3.0GHz，最大加速频率 4.0GHz)，机带 RAM 为 16GB。从雷达实测数据中随机选取一段实测信号，并分别运行 1000 次，各算法平均运行时间如表 2-4 所示。

表 2-4 不同模态分解类算法运行时间

模态分解算法	EMD 算法	VMD 算法	VME 算法
运行时间(s)	0.17	1.56	0.08

由上表可以看出，随着算法推导的优化更新，变分模式分解通过引入优化和变分原理，提高了信号分解的效率。VME 算法通过专注于特定频率的信号提取，运算复杂度大幅降低，算法运行速度更快，迭代次数更少，能够快速收敛。通过对于信噪比和运行时间的比较，选取 VME 算法来抑制干扰和噪声来提取出心跳信号，处理流程如下图 2-13 所示。

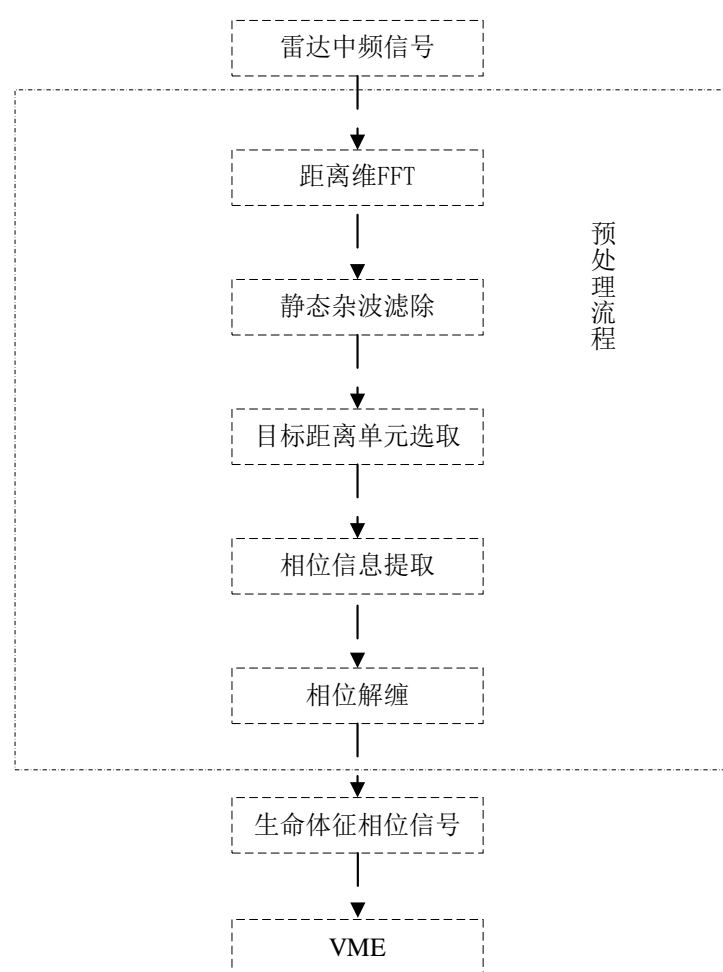


图 2-13 利用 VME 提取心跳信号

2.6 本章小结

本章详细介绍了 FMCW 雷达在生命体征检测方面的原理、方法和应用。首先，阐述了 FMCW 雷达接收和发射信号原理、人体生理学理论基础以及具体的生命体征检测原理。其次，介绍了传统的生命体征检测框架，包括信号预处理算法、对生命体征信号进行了建模分析。最后，通过对比分析了各种模态分解算法，选择了 VME 算法将心跳信号从生命体征信号中分离出来，并说明了其优势和适用性。该章节内容全面涵盖了 FMCW 雷达在生命体征检测方面的理论基础和实践指导，为相关研究和应用提供了重要参考。

3 基于深度学习的干扰抑制算法

上文讲述了如何通过 VME 将心跳信号提取出来，但是人体处于不同状态下，提取出的心跳信号受到的干扰差别较大(比如运动状态下的心跳信号会受到较强的运动伪影的影响，而静止状态下的心跳信号几乎不会受到运动伪影的影响)，为更好地抑制提取心跳信号过程中受到的干扰，本章将通过深度学习的方法对不同状态下心跳信号进行分类并识别，为后续基于 RLS 算法的自适应滤波提供指示，极大的提高了自适应滤波器的滤波效果。

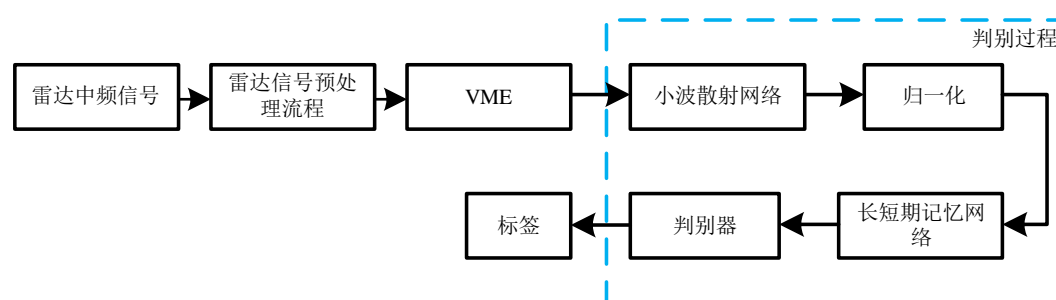


图 3-1 基于深度学习的心跳信号判别模型

3.1 小波散射网络

WSN 是一种用于数字信号特征提取的深度学习模型，其结构类似于 CNN(Convolutional Neural Network)，由卷积层、非线性层以及池化层组成^[48]。WSN 利用小波滤波器进行特征提取，结合卷积层、非线性层和池化层，能够有效地捕获信号的多尺度特征信息，是一种适用于数字信号处理的深度学习模型，这些小波滤波器可以捕捉到信号的局部特征和频率信息。非线性层使用取模函数为网络引入非线性，将卷积层提取的特征进行非线性变换，增强网络的表达能力。池化过程使用平均池化，将卷积层提取的特征进行降维，提高了网络的计算效率，同时保留了重要的特征信息。WSN 在数字信号的特征提取方面具有独特的优势，能够有

效地捕捉信号的局部特征和频率信息，并且具有良好的稳定性和可解释性。

本文使用的数据集均为一维向量形式的雷达信号数据，在这种情况下，使用 WSN 作为整个模型的入口是一个很好的选择，可以有效地处理一维向量形式的雷达信号数据，并且不需要繁琐的人工特征提取过程，可以直接从原始的雷达信号数据中提取出有效的特征表示，为后续的信号处理和分类任务提供有力支持，其网络结构如图 3-2 所示。

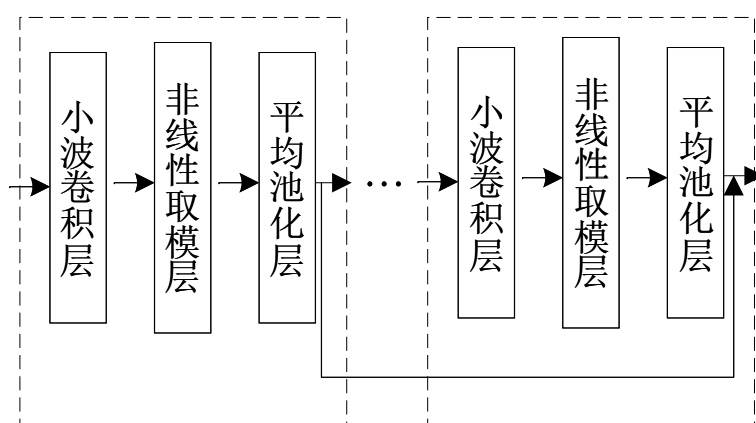


图 3-2 小波散射网络特征提取框架

文献[49]通过大量理论推导证明，使用三层 WSN 即可充分提取输入信号的特征，具体来说，每一层小波散射网络由卷积层、非线性层和池化层组成，这种结构可以有效地捕获信号的多尺度特征信息，并逐步提高信号的抽象表征能力。经过三层网络的堆叠，可以实现对输入信号的全面特征提取，覆盖大部分信号的能量。因此，使用三层小波散射网络构成整个网络框架不仅可以有效地提取信号的特征，而且还能够保证网络的高效性和准确性，适用于对一维向量形式的雷达信号数据进行处理和分析。

对于每一层网络，其构造形式以及参数均被固定，假设输入信号为 x ，其小波变换定义为：

$$U[\lambda]x = |x * \psi_{\lambda}| \quad (3-1)$$

其中， λ 为缩放因子， $*$ 表示卷积操作， ψ_{λ} 为复数小波基。

定义：

$$\|x * \psi_{\lambda}\|_1 = \int |x * \psi_{\lambda}(u)| du \quad (3-2)$$

其中, λ 是缩放因子, 其中 $\psi_{\lambda}(u) = \lambda \psi(\lambda u)$, $\psi(u)$ 可以表示为 Morlet 小波算子, 表示为:

$$\psi(u) = \alpha(e^{iu\xi} - \beta)e^{-|u|^2/(2\sigma^2)} \quad (3-3)$$

式中, α 为正弦波振荡系数, β 高斯衰减系数, $\beta \ll 1$, 其加入的 $\int \psi(u) du = 0$ 。

第 m 层小波散射网络单独作用时的输出包含输入信号在第 m 层上提取的特征信息, 已知 $p = (\lambda_1, \lambda_2, \dots, \lambda_m)$ 为特征提取路径, 可得第 m 层 WSN 单独作用时的输出。数学上, 可以表示为:

$$\begin{aligned} U[p]x &= U[\lambda_m] \dots U[\lambda_2] U[\lambda_1] x \\ &= |||x * \psi_{\lambda_1} | * \psi_{\lambda_2} | \dots | * \psi_{\lambda_m} | \end{aligned} \quad (3-4)$$

这样, 每层网络获取到的特征, 经池化作用, 其特征维度减少, 网络的鲁棒性增强, 其输出可表示为:

$$Sx(p) = \mu_p^{-1} \int U[p]x(u) du \quad (3-5)$$

其中, $\mu_p = \int U[p]\delta(u) du$ 。

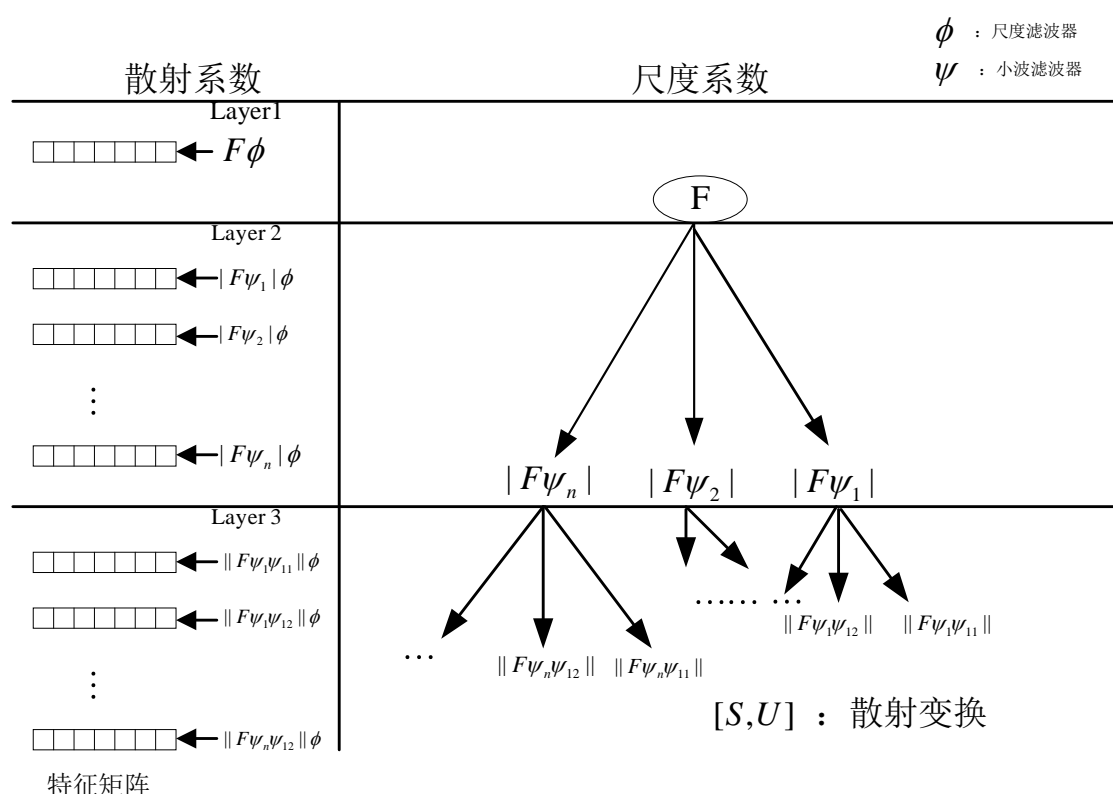



图 3-3 小波散射框架

图 3-3 展示了如何得到散射系数的过程。在第一层，原始信号经过小波变换，将其分解为不同尺度和不同频率的子带信号。这些子带信号反映了信号的局部特征和频率分布。在第二层，对每个尺度的子带信号进行非线性变换和平均池化操作，得到一阶散射系数。一阶散射系数反映了信号在不同尺度下的能量分布和局部特征。第三层，对一阶散射系数进行类似的非线性变换和平均池化操作，得到二阶散射系数。二阶散射系数反映了信号在不同尺度和频率下的更高阶特征和复杂结构。

通过这样逐层的特征提取过程，小波散射网络能够捕捉到信号的多尺度、多频率的特征信息，并且具有较好的稳定性和可解释性。每一层的特征都是基于前一层的特征进行计算和提取的，从而形成了一个层层递进的特征提取过程。因此，对于本次实验来说，3 层小波散射网络足以提取散射特征。

散射系数即提取出的心跳信号小波散射特征。通过设置小波散射网络参数输入信号采样时间 0.06s 和采样频率 4000Hz。小波散射网络会输出一系列的小波系数，这些系数可以被视为输入信号在不同尺度和频率下的特征表示。图 3-4 则是将这些

小波系数整合成一个特征图，其中每个像素对应一个特征。由图 3-4 可以看出，运动状态下心跳信号的小波散射特征在 $0\text{Hz} \sim 4\text{Hz}$ 内均有分布，静止状态下心跳信号的小波散射特征分布在 1Hz 左右。通过小波散射网络提取特征系数后，静止状态下的心跳信号和运动状态下的心跳信号区别明显，易于接下来长短期记忆网络对其进行分类。



(a) 运动状态下心跳信号的小波特征

(b) 静止状态下的心跳信号的小波特征

图 3-4 不同状态下心跳信号的小波散射特征

3.2 长短期记忆网络

心跳信号通过小波散射网络提取的心跳信号小波散射特征由小波散射系数组合而成，每一个小波散射系数在时序上都具有关联性，因此选择具有时间序列数据处理能力的长短期记忆网络^[50]。LSTM 是一种适合处理时序数据的深度学习模型，能够有效地捕获和利用数据中的时间信息，因此非常适合用于处理具有时序关联性的小波散射特征。

1997 年，Hochreiter 和 Schmidhuber 提出了长短期记忆网络，它是对传统循环神经网络(Recurrent Neural Network, RNN)的重要改进。LSTM 将 RNN 中的节点替换为具有存储单元的结构，引入了记忆的概念，以解决 RNN 在处理长期依赖关系时的困难。其核心思想是通过不断更新存储单元的内部状态，保留有用信息并丢弃多余信息，以解决 RNN 中的梯度消失问题。LSTM 引入了三个门机制，包括输入门、遗忘门和输出门，通过这些门来控制信息的流动，使网络能够在长时间内保持

重要特征信息并忽略不重要的特征信息。

在医学领域，虽然不同身体状态下产生的心跳信号的波形可能相似，但整个心跳信号的波形在整体上存在巨大差异。每个心跳周期与前一个周期密切相关。LSTM 在此方面具有独特优势，能够有效地捕获心跳信号的长期波动特征。在心跳信号分析中，LSTM 可以帮助识别和利用前后心跳周期之间的关联性，从而提取出信号的长期波动特征。这种能力对于诊断和监测心脏疾病、评估心脏健康状态等具有重要意义。具体的内部结构可以参考图 3-5。

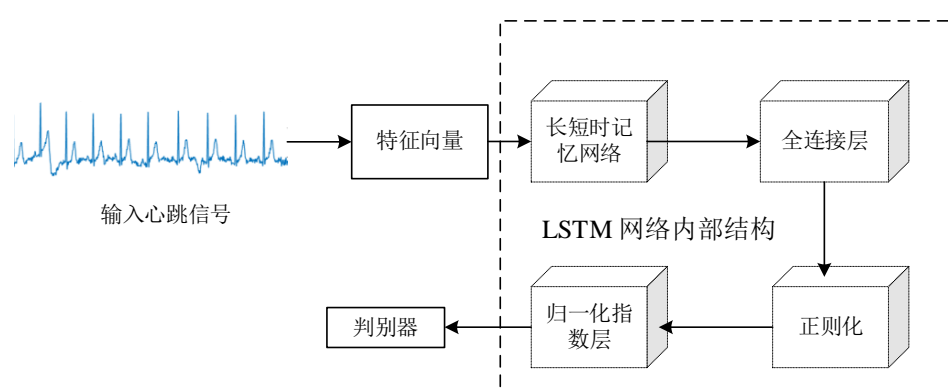


图 3-5 长短期记忆网络内部结构

LSTM 单元通过精妙设计的门控机制，能够有效地处理长序列数据，并学习和记忆序列中的长期依赖关系。三个门均由一个 sigmoid 激活函数和一个点积运算组成，输入门决定当前输入对细胞状态的影响程度。接着，将当前输入和上一个输出作为输入，经过输入门的运算，生成一个更新向量，用于更新细胞状态的一部分。遗忘门决定之前的细胞状态对当前状态的影响程度。该输出用于乘以之前的细胞状态，以确定应该保留多少旧信息。输出门决定当前细胞状态的输出。然后，细胞状态经过 tanh 激活函数处理，并与输出门的输出相乘，得到当前时刻的输出。通过输入门、遗忘门和输出门的精确控制，LSTM 单元能够有效地处理长序列数据，并学习序列中的长期依赖关系。这使得 LSTM 在语言建模、时间序列预测等任务中取得了很好的效果。

细胞状态通过加法运算更新，结合了输入门生成的更新向量和遗忘门乘以之前的细胞状态。这种机制使得 LSTM 能够有效地保留长期依赖关系，同时可以选择性地忘记一些不重要的信息。

LSTM 各个门的公式表示如下：

$$\begin{aligned}
 f_t &= \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \\
 i_t &= \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \\
 \tilde{C}_t &= \tanh(W_c[h_{t-1}, x_t] + b_c) \\
 o_t &= \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \\
 C_t &= f_t * C_{t-1} + i_t * \tilde{C}_t
 \end{aligned} \tag{3-6}$$

式中， C_t 单元状态的输出， h_t 表示为隐藏节点的输出； f_t 是遗忘门， i_t 是输入门， o_t 是输出门，三个门共同控制 h_t 的更新。 σ 为 sigmoid 激活函数，可以将数据压缩到 $[0,1]$ ； \tanh 是双曲正切激活函数，将数据归一化到 $[-1,1]$ ； W 是权值， b 为偏差。

LSTM 通常用于处理连续时间序列问题，而心跳信号作为一种连续时间序列信号同样适用于 LSTM 进行分类处理。本研究将训练迭代次数设定为 500 次，并采用单个 GPU 进行训练。本次训练使用的训练集为毫米波雷达的实测数据集，共 500 人次，包含不同年龄、不同性别、不同地区和不同 BMI。测试集为 19 人次，包含静止和运动两种情况，与训练集分开，不参与训练。

图 3-6 为 WST-LSTM 模型训练的准确率和损失函数的变化情况，可以看出准确率随着训练次数增加而增加，在 120 次时准确率趋于稳定。可以看出损失函数随着训练次数逐渐减小，在 120 次时趋于稳定，模型对于数据的拟合程度较好。通过图 3-6 的观察，可以发现在大约 120 次训练后，准确度和损失已经达到了较好的结果。图 3-7 为测试集在本模型的训练的结果，通过混淆矩阵可以看出运动状态下心跳信号的判别均正确，正确率为 100%，静止状态下心跳信号的判别出现 1 例错误，正确率为 93.3%，小波散射-长短期记忆网络在处理小样本一维时序数据时表现出卓越的性能。与此同时，判别错误的心跳信号是由于身体的随机性运动过大，导致错误判别。但是正因如此，我们在后续的基于 RLS 的自适应滤波可以采用运动状态下的参考信号，仍能达到较好地滤波效果。

在该阶段，模型表现出 95% 的正确率，成功完成对心跳信号状态的判别。这为后续基于 RLS 的自适应滤波器提供了有力的指导，为信号处理提供了更为可靠的基础。通过 LSTM 在心跳信号分类中的应用，本研究不仅实现了较好的准确度和损

失结果，还为进一步的自适应滤波工作奠定了基础。小波散射-长短期记忆网络的成功应用为处理小样本时序数据提供了新的可能性，为医疗监测和信号处理领域带来了有益的探索。




图 3-6 心跳信号模型训练过程

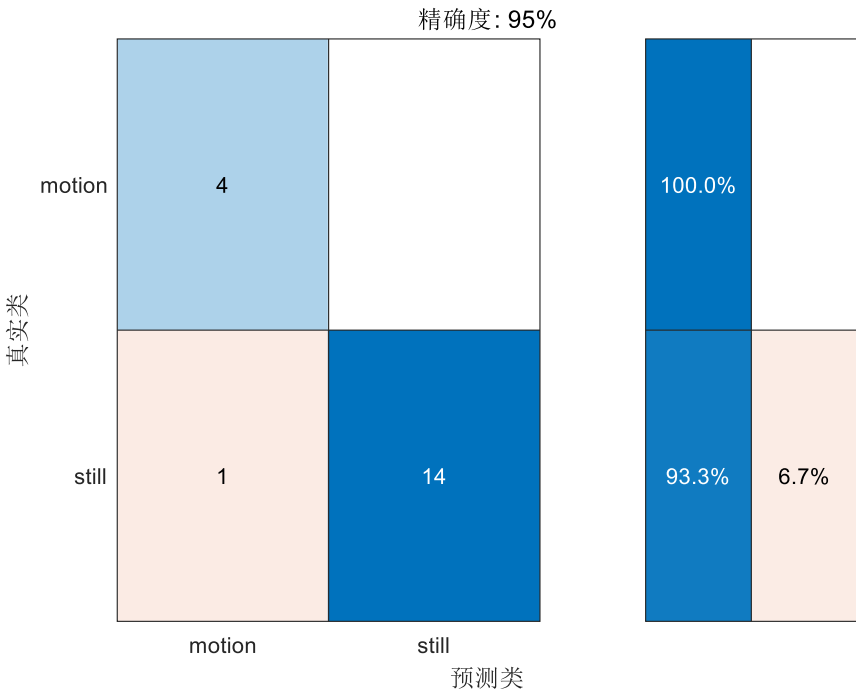


图 3-7 心跳信号模型状态判断准确率

3.3 自适应滤波去噪算法

滤波理论早在 20 世纪初就已经形成,并且在信号处理领域得到了广泛应用。最初的滤波器主要是基于固定的线性滤波器设计的,例如低通滤波器、高通滤波器等。然而,这些固定的滤波器在处理复杂的信号时可能效果不佳,因此人们开始尝试开发自适应滤波器来应对不同的信号特性。自适应滤波中常用的算法为 RLS 算法^[51]。

RLS 算法基于最小二乘法,通过预测最小化误差的平方和来估计参数。它采用递归更新的方式,不断地更新参数估计,以适应新的观测数据。在每次接收到新的数据时,只需要进行一次计算,而不需要重新计算整个数据集的误差函数。这使得算法具有高效的计算性能。RLS 算法使用指数加权平均的方法来更新参数估计。新的数据点被赋予更高的权重,而旧的数据点则被赋予更低的权重,这样可以更好地适应数据的变化。

在递归最小二乘自适应滤波器中,对于某个给定时刻 k , 输入信号向量 $x(k)$ 为:

$$x(k)=[x(k)x(k-1)\dots x(k-N)]^T \quad (3-7)$$

其中, N 表示为滤波器阶数,对滤波器权系数向量 $W_j(k), j=0,1,\dots,N$ 的自适应调整,使得 RLS 的目标函数最小化,RLS 目标函数为:

$$\xi^d(k)=\sum_{i=0}^{\pi}\lambda^{k-i}\varepsilon^2(i)=\sum_{i=0}^{\pi}\lambda^{k-i}[d(i)-x^T(i)w(k)]^2 \quad (3-8)$$

$$\frac{\partial \xi^d(k)}{\partial w(k)}=-2\sum_{i=0}^k\lambda^{k-i}x(i)[d(i)-x^T(i)w(k)] \quad (3-9)$$

其中, λ 为遗忘因子且 $\lambda \in (0,1)$, $\varepsilon(i)$ 为时间 i 处的残差, $d(i)$ 为观测值, $w(k)$ 为参数向量。

令上式为 0 可得:

$$-\sum_{i=0}^k \lambda^{k-i} x(i) x^T w(k) + \sum_{i=0}^k \lambda^{k-i} x(i) d(i) = \begin{bmatrix} 0 \\ 0 \\ \dots \\ 0 \end{bmatrix} \quad (3-10)$$

所有 $w(k)$ 的表达式为:

$$w(k) = [\sum_{i=0}^k \lambda^{k-i} x(i) x^T(i)]^{-1} \sum_{i=0}^k \lambda^{k-i} x(i) d(i) = R_D^{-1}(k) p_D(k) \quad (3-11)$$

其中, $R_D(k)$ 是式 3-5 之间的自相关矩阵, $p_D(k)$ 为 $x(k)$ 和 $d(k)$ 之间的互相关矩阵。

下面为 RLS 算法步骤的完整描述^[52]:

Step1: 设横向滤波器抽头权值向量 $w(k)$ 以及自相关矩阵的逆矩阵 $p(k)$ 在初始时刻的值:

$$w(0) = 0 \quad (3-12)$$

$$p(0) = \delta^{-1} I \quad (3-13)$$

式中, δ 为一个小值的正常数, I 为单位矩阵。

Step2: 重复递归计算

对于每一时刻的 $n=1,2,3,\dots$ 依次加 1, 然后按下述步骤顺序进行计算:

(a) 更新增益向量值 $z(k)$;

$$z(k) = \frac{\lambda^{-1} p(k-1) x(k)}{1 + \lambda^{-1} x^T(k) p(k-1) x(k)} \quad (3-14)$$

(b) 更新估计残差值 $e(k)$;

$$e(k) = d(k) - w^T(k-1) x(k) \quad (3-15)$$

(c) 更新滤波器抽头权值向量 $w(k)$;

$$w(k) = w(k-1) + z(k) e(k) \quad (3-16)$$

(d) 更新自相关矩阵的逆矩阵 $p(k)$;

$$p(k) = \lambda^{-1} (p(k-1) - z(k) w^T(k) p(k-1)) \quad (3-17)$$

(e) 令 $k = k+1$, 返回计算步骤(a),且重复(a)到(d)的步骤, 直至估计误差数值满足要求。

图 3-8 即为设计的 RLS 自适应滤波器的原理框图。其中，参考信号 $d(k)$ 根据深度学习对于当前输入信号状态的判断进行自适应的选择，以保证滤除静止状态下心跳信号中的身体随机运动、呼吸谐波和差拍信号等干扰，滤除运动状态下心跳信号中的身体运动、身体随机运动引起的干扰、呼吸谐波和差拍信号等干扰。以实现基于 RLS 算法的自适应滤波器能够达到优异的滤波效果。

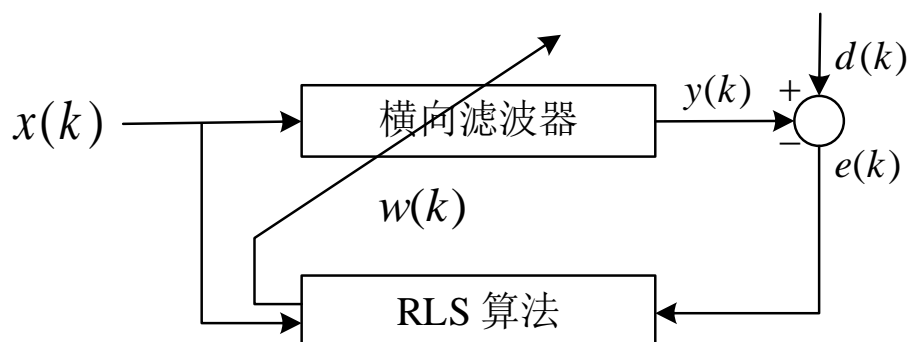


图 3-8 基于 RLS 算法的自适应滤波器


图 3-9 和图 3-10 展示了同一组心跳信号，在经过基于深度学习的自适应滤波前后，对比运动伪影滤除效果的变化。由图 3-9(b)和图 3-10(b)可以看出未经深度学习的心跳信号的频谱图包含假峰，经深度学习进行心跳信号状态判别的心跳信号频谱较为干净。本文默认 VME 均选择相同参数，由图 3-9(b)可知，仅用 VME 从生命体征信号中提取的心跳信号仍包含呼吸谐波、运动伪影和交调信号等干扰，会形成心跳假峰，干扰心率估计。从图 3-10(b)可以看出，处理后的信号相比原始心跳信号，大部分由于呼吸谐波、运动伪影和交调信号等干扰造成的假峰得到了有效抑制。

基于深度学习的自适应滤波方法应用于该组心跳信号具体处理步骤是：经 VME 分解后的心跳信号输入到小波散射网络，提取小波特征，并判断心跳信号运动状态，而后通过心跳信号运动状态选择基于 RLS 的自适应滤波器的参考信号，参考信号来源于 Physio Net's ECG-ID，PhysioNet's ECG-ID 数据集是一个公开的心电信号数据集，由 PhysioNet 提供。该数据集包含不同来源的心跳信号，包括各种不同状态下的心率数据。除了心跳信号本身之外，该数据集还包含了相应的注释信息，如运动的具体形式、测试时的身体状态等。在这个数据集中，心跳信号的干扰可以来自多个方面：

运动和肌肉运动导致的运动伪影：在采集心跳信号时，患者的运动或肌肉活动可能导致信号中的运动伪影，表现为高频、低幅度的噪声。

生物学噪声：生物学噪声包括来自呼吸、肌肉运动、身体活动等生理过程的信号变化，可能在心跳信号中引入随机噪声。对该组呼吸谐波、运动伪影和交调信号等干扰进行滤除。

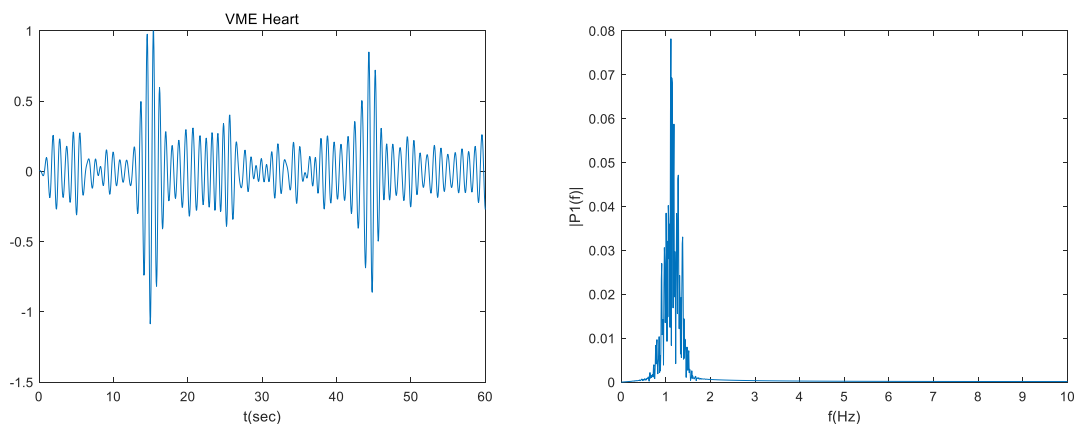
以上实验结果说明，当使用深度学习对心跳信号的状态进行先验判别时，再使用基于 RLS 算法的自适应滤波进行干扰抑制能够取得更好地效果。



(a) 自适应滤波前心跳信号波形

(b) 自适应滤波前心跳信号的频谱图

图 3-9 基于 RLS 自适应滤波前心跳信号的波形图及其频谱图

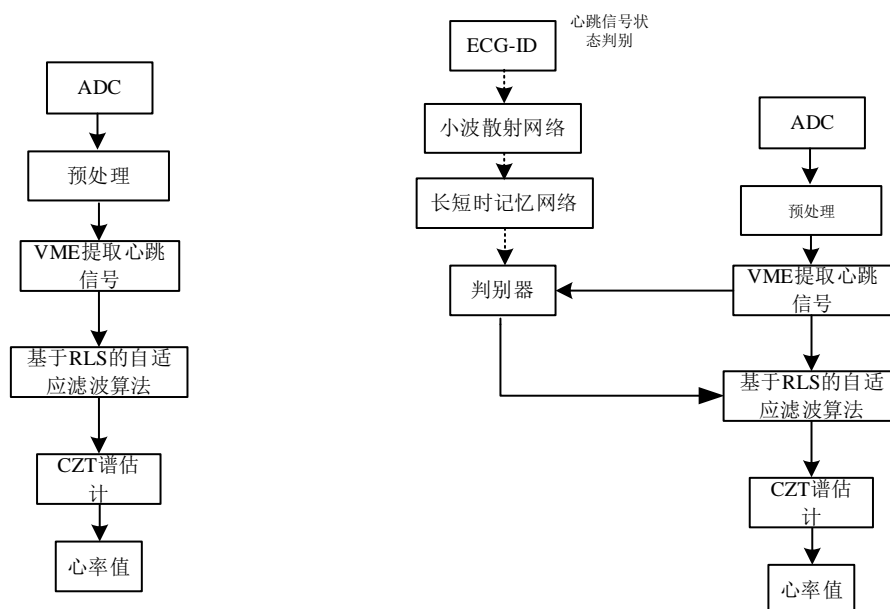


(a) 自适应滤波后心跳信号波形

(b) 自适应滤波后心跳信号频谱图

图 3-10 基于 RLS 自适应滤波后心跳信号的波形图及其频谱图

3.4 实验结果分析



(a) 方法一的流程图

(b) 方法二的流程图

图 3-11 不同方法下的基于 RLS 自适应滤波心率估计的流程图

接下来，我们将通过实测数据验证这一方法的有效性。在实测数据采集过程中，被测者位于 FMCW 雷达的正对方向。在实验中，被测者有两种状态，一种是静止状态，另一种是存在运动的状态(前倾、后仰、摇晃和挥舞手臂等)。在实验结果对比分析中，我们比较了方法一(基于 RLS 算法的自适应滤波)、方法二(基于深度学习的 RLS 自适应滤波)的干扰滤除性能。表 3-1 和表 3-2 分别展示了 7 名志愿者在不同身体状态下，基于 RLS 算法的自适应滤波和基于深度学习的 RLS 自适应滤波方法的心率估计性能。

表 3-1 静止状态下的心率检测结果

志愿者	状态	方法一 MAE/bpm	方法二 MAE/bpm
1	静止	3.48	2.11
2	静止	3.37	2.48
3	静止	2.17	1.6
4	静止	4.31	3.11
5	静止	4.62	3.25
6	静止	4.51	2.48
7	静止	5.57	3.54
平均值		4.08	2.65

表 3-2 运动状态下的心率检测结果

志愿者	状态	方法一 MAE/bpm	方法二 MAE/bpm
1	运动	4.57	2.57
2	运动	8.28	5.11
3	运动	15.51	3.34
4	运动	11.97	2.22
5	运动	12.65	5.02
6	运动	17.37	3.68
7	运动	13.31	3.62
平均值		11.95	3.36

如表 3-1 所示, 在静止状态下, 心跳信号受到呼吸谐波、交调信号以及环境噪声的影响, 基于深度学习的自适应滤波算法相较于未经深度学习判别心跳信号的运动状态的自适应滤波算法的平均提高了 1.43bpm, 其心率估计为 2.65bpm 可以较好的反映静止状态下心跳信号的指征。从表 3-2 可以看出在运动状态下, 心跳信号受身体运动的影响非常大。在未对心跳信号的状态进行判别, 并选择合适的参考信号时, 只使用自适应滤波和谱分析方法对心率估计的平均 MAE 高达 11.95bpm。然而, 当对心跳信号的状态进行判别, 并自适应选择合适的参考信号后, 心跳信号的平均心率估计为 3.36bpm。相比于未经深度学习的自适应滤波方法, 深度学习使心率估计精度提高了 8.59bpm。

基于以上实验结果和分析, 可以得出, 基于 RLS 算法的自适应滤波方法无法

处理不同状态下的心跳信号的干扰，且当身体处于运动状态下，高强度的身体运动会给心跳信号造成极强的干扰，简单的基于 RLS 算法自适应滤波算法无法很好的滤除运动伪影，此外，在被测者静止状态下，心率检测的效果可能会下降。与之相比，我们提出的基于深度学习的自适应滤波方法在本文的实验中，不论处理何种状态下的心跳信号，都展现出了更优异的性能，能够更好地抑制干扰并滤除杂波。以上实验结果充分表明：基于深度学习的自适应滤波方法，通过深度学习的方法，实现了对心跳信号的先验判别，为后续进行基于 RLS 的自适应滤波方法选择了合适的参考信号，其抑制干扰、滤除杂波的能力要优于单纯的基于 RLS 的自适应滤波方法。




图 3-12 运动状态下不同方法的心率曲线图

图 3-12 呈现了心跳信号在运动情况下，分别采用方法一和方法二得到的心率变化曲线。在图中，红色曲线代表使用 Polar H10 胸部心率传感器获取的心率变化曲线。而绿色曲线则表示经过深度学习的自适应滤波方法和使用谱分析方法所得到的心率变化曲线。而蓝色曲线则代表本文提出的方案，即经过深度学习后，再经过自适应滤波处理，并使用谱分析方法得到的心率变化曲线。对于图 3-12 中各个心率曲线的演变趋势进行分析后，我们可以发现蓝色曲线，即采用深度学习的自适应滤波方法得出的心率变化曲线，与参考曲线相比呈现出最相近的趋势。相对而言，

未经过心跳信号状态判别的心率变化曲线，即绿色曲线，与参考心率变化曲线之间存在显著的偏差。

通过进一步比较绿色和蓝色心率变化曲线，我们可以观察到，未经深度学习进行心跳信号状态判别的自适应滤波方法具有一定程度的干扰抑制能力，但其效果较为有限。与参考心率相比，绿色心率变化曲线的 MAE 为 4.57bpm，而蓝色心率曲线的 MAE 为 1.54bpm，在心率检测方面取得的改进 MAE 为 3.03bpm。

3.5 本章小结

本章主要介绍了基于深度学习的基于 RLS 算法的自适应滤波方法。首先介绍了小波散射网络，通过小波散射网络提取不同状态下心跳信号的小波散射系数。随后，应用长短期记忆网络对其进行分类，训练网络模型。然后将经 VME 提取后的心跳信号输入到判别器，判断心跳信号的状态，根据心跳信号的状态，自适应的选取对应状态的参考信号，并将心跳信号输入基于 RLS 算法的自适应滤波中，滤除呼吸谐波、运动伪影、交调信号等干扰。该方法创新性的使用深度学习的方法对心跳信号的状态进行判别，同时提取了小波特征，大大简化了运算量，缩短了模型训练时间。相比与传统的自适应滤波方法，该方法可以自适应的选择参考信号，大大提高了自适应滤波的性能，不需要手动调节参数，增强了算法在不同状态下的鲁棒性。

深度学习模型具备出色的学习和泛化能力，可以为后续基于 RLS 的滤除过程自适应的选择参考信号提供指示，无需手动调节参数。基于深度学习的自适应滤波方法在信号处理领域具有重要的应用前景和广阔的发展空间，能够在实际应用中取得较好的滤波效果和性能提升。

4 基于卡尔曼滤波的时频融合心率估计方法

心率值估计作为毫米波雷达非接触式生命体征检测技术的最后一步，仍存在干扰和噪声影响心率值的估计，本章采用基于卡尔曼滤波的时频域融合心率计算方法，通过对时域心率估计值和频域心率估计值进行数据融合，提高了心率值的精度和鲁棒性。时域心率测量通过计算连续两个R峰之间的时间间隔，然后将时间间隔转换为心率。在频域心率测量中，采用线性调频Z变换将心跳信号变换到频域范围。通过频谱分析找出真实心率对应的峰值点，使用这些峰值点对应的频率来计算心率。这种融合方法结合了时域和频域的优势，为心率检测提供了更为综合和可靠的解决方案。

4.1 心跳信号时域估计

在时域分析中，可以使用局部极大值方法来检测心跳信号，并计算相邻极大值之间的时间间隔来估计心率值。在预处理后的信号中，使用波峰搜索检测局部极大值，这些极大值对应于心脏每次搏动时的信号峰值。对于检测到的局部极大值，计算相邻两个极大值之间的时间间隔，即相邻极大值的间隔时间。需要注意的是，这种方法假设信号中只包含一个主要的心跳信号，并且没有严重的噪声干扰。在时域分析中，心率计算公式如下：

$$BPM = \frac{60 \times F_s}{T} \quad (4-1)$$

其中， F_s 代表心跳信号采样频率， T 代表脉搏波相邻极大值点之间的距离，BPM 为心率值。

时域估计心率值的过程中，会存在心跳信号的假峰，极大的干扰了时域心率值的正常估计。峰谷差值去噪方法可以在时域心率估计中起到降噪、平滑信号和提取有效信息的作用，从而提高心率估计的质量和准确性。为了获得平滑的心跳信号或减少干扰，我们使用峰谷差值去噪方法来消除时域中的额外噪声^[53]。主要步骤如下所述：

(1)寻找峰值和谷值：在经 RLS 自适应滤波后的心跳信号中，通过波峰搜索寻找信号的峰值和谷值。这些峰值和谷值对应于信号的极值点。

(2)计算峰谷差值：对于每一个峰值和其对应的谷值，计算它们之间的差值。这个差值反映了信号的波动程度，可以用来评估信号的变化情况。 F_i 为峰值， G_i 为谷值。定义 C_i 为峰值和谷值之间的差值。那么可以得到式(4-2)：

$$C_i = F_i - G_i, i = 1, 2, \dots, n \quad (4-2)$$

(3)去除噪声：根据峰谷差值的大小，可以将那些峰谷差值小于 0.3 的部分认为是噪声，并将其过滤或剔除掉。

为了消除时域波形中的无效心跳波形，我们使用了固定阈值的峰谷差值算法滤除无效的心跳信号波形，经过这一步骤，得到的心跳信号的波形均为有用的心跳信号的波形，为后续波峰确定奠定基础。经过准确的波峰确定，通过计算相邻波峰间的距离，得到准确的时域估计心率值。所得结果如图 4-1 所示。




图 4-1 峰谷差值法

从图 4-1 中可以看出，保留下来的心跳信号波形峰谷差值均大于 0.3，得到的心跳信号波形均为心跳信号的有用波形。对得到的心跳信号进行波峰确定，计算出两个相邻波峰间的距离，代入式(4-1)，可得出心率值。为了提高心率估计值的准确性，我们将窗长设置为 512 点，步长为 20 点，每秒钟滑动一次。最终得到时域

估计心率值。

4.2 心跳信号频域估计

线性调频 Z 变换(Chirp-Z)对获取信号上包含心跳基波信息的一小段频率范围的频谱进行细化分析, 来提高峰值点频率的测量精度, 从而提高心率检测精度^[54]。

Chirp-Z 转换的频谱精细化机制如下:

通过运用 Z 变换的原理, 对长度为 N 的有限序列 $x(n)$ 进行转换, 得到:

$$X(z) = \sum_{n=0}^{N-1} x(n)z^{-n} \quad (4-3)$$

在 Z 平面上的单位圆内, 以等间隔角度采样某一段螺旋线, 其采样点可表示为:

$$z_k = AW^{-k}, k = 0, 1, \dots, M-1 \quad (4-4)$$

式中的 M 是期望的频谱细化的点数。

结合式(4-3)和式(4-4), 又因为 $A = A_0 E^{j\theta_0}$, $W = W_0 e^{j\varphi_0}$ 则

$$z_k = A_0 e^{j\theta_0} W_0^{-k} e^{jk\varphi_0} = A_0 W_0^{-k} e^{j(\theta_0 + k\varphi_0)} \quad (4-5)$$

$$z_{M-1} = A_0 W_0^{-(M-1)} e^{j[\theta_0 + (M-1)\varphi_0]} \quad (4-6)$$

其中, A_0 为起始抽样点 z_0 的模值, $A_0 \leq 1$, 表示抽样点都坐落于单位圆内部。 θ_0 为起始相位角, φ_0 为两个相邻抽样点 z_k 与 z_{k-1} 之间的角频率差值。螺旋线的延伸率为 w_0 , 如果 $w_0 < 1$, 那么当 k 增加时, 单位圆会向内收缩; 如果 $w_0 > 1$, 而当为, 单位圆则会随着 k 增大而向外伸展。

在单位圆上进行 Chirp-Z 变换时, $A_0 = 1, W_0 = 1$, 将上式中的 z_k 代入式(4-3)可得:

$$X(z_k) = \sum_{n=0}^{N-1} x(n) A^{-n} W^{nk}, k = 0, 1, \dots, M-1 \quad (4-7)$$

实际实现时采用求卷积和的方式来计算 CZT 算法。将 $nk = \frac{1}{2}[n^2 + k^2 - (k-n)^2]$ 代入上式:

$$X(z_k) = W^{\frac{k^2}{2}} \sum_{n=0}^{N-1} [x(n) A^{-n} W^{\frac{n^2}{2}}] W^{-\frac{(k-n)^2}{2}} \quad (4-8)$$

设 $g(n) = x(n) A^{-n} W^{\frac{n^2}{2}}, h(n) = W^{\frac{n^2}{2}}$, 则上式可改写为:

$$X(z_k) = W^{\frac{k^2}{2}} [g(n) * h(k)], k = 0, 1, \dots, M-1 \quad (4-9)$$

由于 $h(n)$ 序列的类似性质, 我们将其转化为了 Chirp 信号, 从而得到了 Chirp-Z 变换。该变换的计算过程如图 4-2 中所展示。

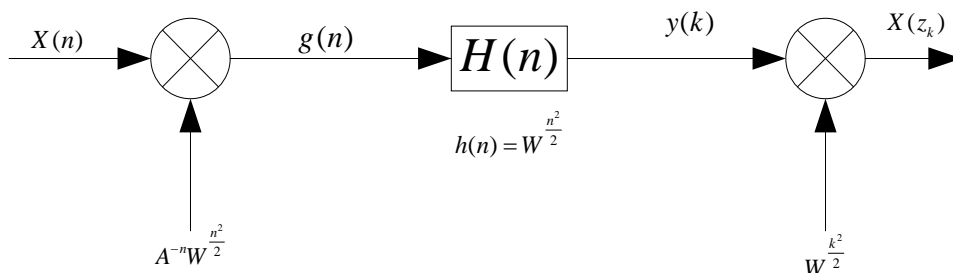


图 4-2 线性调频 Z 变换流程图

综上所述, CZT 通常具有更高的精度, 可以实现对信号进行任意频率偏移, 而 FFT 只能实现对信号进行等间隔频率采样。这使得 CZT 在一些特定的信号处理任务中更加灵活, 例如频率调制和解调。

4.3 卡尔曼滤波原理

卡尔曼滤波算法是一种递归的状态估计方法, 通过有效地融合系统动态模型和观测数据, 实现对系统状态的优化估计。本章重点介绍了卡尔曼滤波算法的数学推导过程^[55], 详细阐述了时间预测和测量更新步骤中所涉及的数学原理和推导过程。

我们建立了系统的状态空间模型, 包括状态方程和观测方程:

$$x_k = Ax_{k-1} + Bu_{k-1} + w_{k-1} \quad (4-10)$$

$$z_k = Hx_k + v_k \quad (4-11)$$

其中, x_k 是系统在时刻 k 的状态向量, u_k 是控制输入, w_k 和 v_k 分别是过程噪声和观测噪声, 假设为零均值的高斯白噪声, A 为状态转移矩阵, B 为控制输入矩阵, H 为观测矩阵。

时间预测是卡尔曼滤波的第一步, 其中通过状态方程对系统状态进行预测。预测状态 $x_{k|k-1}$ 和预测误差协方差矩阵 $P_{k|k-1}$ 分别表示为:

$$x_{k|k-1} = A_k x_{k-1} + B_k u_k \quad (4-12)$$

$$P_{k|k-1} = A_k P_{k-1|k-1} + Q_k \quad (4-13)$$

其中, Q_k 是过程噪声的协方差矩阵。

测量更新是卡尔曼滤波的关键步骤, 其中利用观测数据预测状态进行修正。卡尔曼增益和更新后的状态估计表示为:

$$\begin{cases} K_k = P_{k|k-1} H_k^T (H_k P_{k|k-1} H_k^T + R_k)^{-1} \\ x_{k|k} = x_{k|k-1} + K_k (z_k - H_k x_{k|k-1}) \\ P_{k|k} = (I - K_k H_k) P_{k|k-1} \end{cases} \quad (4-14)$$

其中, R_k 是观测噪声的协方差矩阵, K_k 是卡尔曼增益, $x_{k|k}$ 是时间步 k 的更新状态估计, $P_{k|k}$ 是更新误差协方差矩阵, I 是单位矩阵。

根据新的观测数据, 重复进行时间预测和测量更新步骤, 以获得连续的状态估计序列。卡尔曼滤波的算法可以总结为图 4-3 所示。

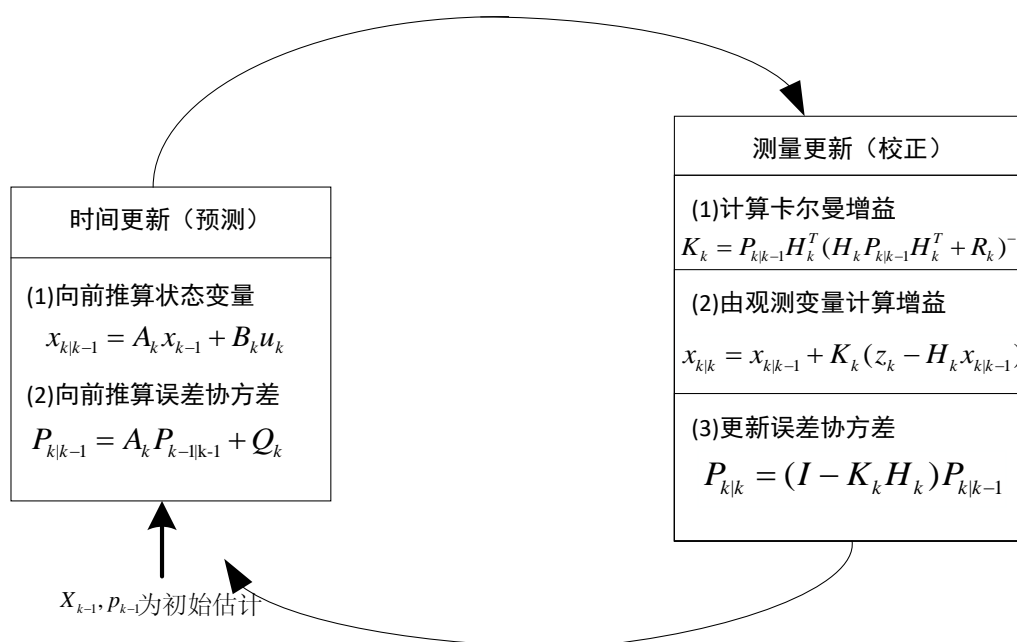


图 4-3 卡尔曼滤波过程图

4.4 基于卡尔曼滤波的数据融合心率估计方法

基于 4.1、4.2 和 4.3 的研究成果，我们在本文中引入了一种心率估计方案。该方案采用卡尔曼滤波技术，将时域和频域心率估计相结合，以提高心率估计的稳健性，实现准确和稳定的人体心率跟踪。这里峰谷差值所得的心率估计值作为预测值直接通过式(4-12)在预测步骤使用，而线性调频 Z 变换所得的心率估计值作为观测值用于校正这个预测，以获得更精准的心率估计值。KFTF 心率估计的信号处理流程框图如图 4-4 所示。

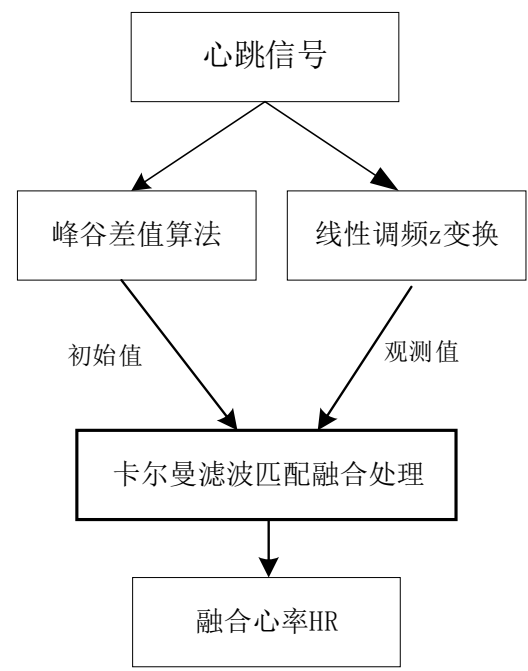


图 4-4 基于卡尔曼滤波的心率估计方法

KFTF 包括以下几个信号处理步骤。首先，我们对心跳信号进行了滑动时间窗口的处理。接着，利用峰-谷差值确定的时域心率值作为卡尔曼滤波的初始值，并应用 CZT 谱分析方法确定该时间窗口的心率作为观测值。随后，我们将当前滑动窗口内的观测值和峰-谷差值确定的时域心率值进行卡尔曼滤波，以获得精确的心率估计值。

我们将心率初始值表示为 $\hat{x}_{\bar{k}}$ ，心率观测值表示为 z_k ，心率的融合估计值为：

$$\hat{x}_k = \hat{x}_{\bar{k}} + K(z_k - \hat{x}_{\bar{k}}) \tag{4-15}$$

其中， K 为卡尔曼增益。

我们要使心率估计值尽量准确，方差 $\sigma_{x_k}^2$ 要尽可能小。

$$\sigma_{x_k}^2 = \text{var}[\hat{x}_k] = \text{var}[\hat{x}_{\bar{k}} + K(z_k - \hat{x}_{\bar{k}})] \tag{4-16}$$

已知心率初始值 $\hat{x}_{\bar{k}}$ 和心率观测值 z_k 互相独立：

$$\text{var}(x_1) = \sigma_1^2 \quad \text{var}(x_2) = \sigma_2^2 \quad (4-17)$$

$$\sigma_{x_k}^2 = \text{var}[(1-K)x_1] + \text{var}(Kx_2) = (1-K)^2 \text{var}(x_1) + K^2 \text{var}(x_2) \quad (4-18)$$

$$\sigma_{x_k}^2 = (1-K)^2 \sigma_1^2 + K^2 \sigma_2^2 \quad (4-19)$$

对 K 求导，得方差最小值点：

$$\frac{d\sigma_{x_k}^2}{dk} = -2(1-K)\sigma_1^2 + 2K\sigma_2^2 = 0 \quad (4-20)$$

$$K = \frac{\sigma_1^2}{\sigma_1^2 + \sigma_2^2} \quad (4-21)$$

将 K 值代入式(4-19),便可以进行数据融合得到一个更加准确的数据。这种融合方式利用了卡尔曼滤波的原理，在不增加计算量的基础上，将时域与频域的心率估计值融合起来，提高了心率检测的精度和鲁棒性。

这里由峰谷差值算法所得的心率估计值可作为完整的心率融合过程预测值，无需通过上个时刻状态进行预测，而线性调频 Z 变换所得的心率估计值提供了观测值，我们将使用卡尔曼滤波算法将这些信息合并起来获得更准确的状态估计，具体流程如下所示：

对于每个时间步 k ：

1.由峰谷差值算法估计心率值可得：

\hat{x}_k = 预测值， P_k = 预测误差协方差。

2.由线性调频 Z 变换估计心率值可得：

z_k = 观测值。

3.更新步骤：

计算卡尔曼增益： $K_k = P_{k|k-1} H_k^T (H_k P_{k|k-1} H_k^T + R_k)^{-1}$ 。

更新状态估计： $x_{k|k} = x_{k|k-1} + K_k (z_k - H_k x_{k|k-1})$ 。

更新误差协方差： $P_{k|k} = (I - K_k H_k) P_{k|k-1}$ 。

进行迭代计数： $k = k + 1$

若所有观测值处理完毕，终止迭代过程。

表 4-1 为经深度学习判别信号状态后经 RLS 自适应滤波的心跳信号进行不同心率估计方法的对比，为了保证数据的多样性，我们选取了四名男性、四名女性，由表中数据可以看出，KFTF 相较于峰谷差值估计心率值提高了 1.5bpm，相较于 CZT 估计心率值提高了 1.1bpm，提高了心率估计的准确性。同样，KFTF 相较于峰谷差值心率估计的标准差提高了 0.8，相较于 CZT 估计心率值的标准差提高了 0.43，展现出较强的鲁棒性。

表 4-1 不同心率估计方法估计心率值

被测者	性别	CZT 估计	峰谷差值估计	KFTF 估计
		MAE/bpm	MAE/bpm	MAE/bpm
1	男	2.68	2.3	1
2	男	2.14	1.97	1.31
3	男	3.08	1.4	1.22
4	男	2.22	3.25	1.62
5	女	0.68	3.74	1.42
6	女	4.02	2.2	1.28
7	女	2.62	2.57	0.8
8	女	3.11	5.91	2.57
平均值		2.57	2.95	1.40
标准差		0.90	1.32	0.47

我们对所获得的实测信号进行了处理，并通过与多种心率估计方案进行比较，验证了 KFTF 方法在心率估计中的准确性。为确保性能比较的科学性，我们对相同的心跳信号数据集应用了不同的心率估计方案。图 4-5 呈现了不同心率估计方案所得心率估计结果的对比。在图中，粉色表示采用 CZT 谱分析方法得出的心率估计值；绿色代表基于峰-谷差值的时域估计心率值；蓝色代表采用 KFTF 方法估计得到的心率值；而红色则表示心率带提供的参考心率值。




图 4-5 基于卡尔曼滤波的时频域融合心率估计图

从图 4-5 中可以看出, 时域估计得到的心率值在 0s~16s 和 22s~35s 均有一定的差距, 不能很好的反映心率信号的变化趋势, 在 16s~22s 时与参考心率带的变化趋势相反。频域估计得到的心率值在 0s~33s 均有偏差, 不能很好的反映出心率的变化情况, 基于 KFTF 得到的心率估计值在 0s~8s 和 10s~25s 与参考心率值相同, 且能够很好的反映心率变化的趋势, 这对于心率检测的意义十分重要, 意味着心率检测的方法可以及时的反映心跳的变化情况。可以看出时域心率估计方法在极大程度上弥补了频谱心率估计方法难以跟随心率变化这一短板, 而频域估计方法相对于时域而言具有较高的精确度, 二者通过卡尔曼滤波在数据层进行融合, 取得了较好的效果。

使用 KFTF 方法进行心率估计相比直接使用 CZT 频谱分析方法, 可以将心率估计性能提高 1.85bpm。比单纯使用时域心率方法, KFTF 方法性能提高了 2.22bpm。我们通过与单纯的时域心率估计方法和单纯的频域估计相比较, 证明了 KFTF 方法在心跳信号估计方法具有较强的优势。通过该算法, 我们能够获得相对准确的心率检测结果, 并且这些结果能够较好地反映心率的变化情况。

4.5 本章小结

本章主要介绍了基于卡尔曼滤波的时频分析技术在心跳信号处理中的应用，以及提出的新型心率估计方法。首先，我们从时域和频域两个角度概述了新方法的原理和流程。在时域方面，我们采用了峰-谷差值的方法来计算心率值。而在频域方面，我们利用线性调频 Z 变换来替代传统的 FFT，从而提高了谱估计的精度，以便更准确地估计心率。而后，为了充分利用时频域估计的心率值引入了卡尔曼滤波算法，得到融合后的心率值。研究表明，KFTF 方法在精确测量心率值方面表现更佳。最后，我们概述了 KFTF 算法的处理过程，并通过实验证实了该方法在抑制噪声和干扰方面的有效性，进而提升了心率检测的准确性和可靠性。

5 基于 FMCW 雷达的生命体征检测实验及结果分析

为了评估基于深度学习的毫米波雷达非接触生命体征检测方案的性能，我们通过 AWR1642 雷达传感器和 DCA1000EVM 数据采集板获取真实的生理信号数据，并与基于 VMD 的非接触式生命体征检测方案和基于 VME 的非接触式生命体征检测方案进行比较，在实验室环境中对本文所提方案进行验证和评估。

5.1 实验设置

本研究采用了 Texas Instruments 的 AWR1642 和 DCA1000EVM 的组合来负责人体心率数据的采集工作。AWR1642 采用了低功耗 45 纳米 RFCMOS 工艺制造，在超小的外形中实现了非常高的集成度。

5.1.1 毫米波雷达

AWR1642 是德州仪器(Texas Instruments)推出的一款基于毫米波技术的短距离雷达传感器^[56]。它具有许多优势和特点，使其在各种应用中得到广泛应用，包括生命体征检测、智能交通、自动驾驶、工业自动化、智能家居等领域。图 5-1 为 AWR1642 雷达开发板实物图。





图 5-1 AWR1642 雷达传感器

AWR1642 具有高分辨率的毫米波雷达传感器，能够在短距离范围内精确地探

测和定位目标物体。并且集成了多种传感器功能，包括雷达、惯性测量单元(IMU)、温度传感器等，具有多种感知能力，可用于复杂环境下的感知和决策。AWR1642 具有快速的数据采集和处理能力，能够实时检测和跟踪高速移动的目标，适用于需要快速响应的应用场景。

5.1.2 数据采集卡



(a) DCA1000 数据采集板-正面

(b) DCA1000 数据采集板-背面

图 5-2 DCA1000 数据采集板

DCA1000 是德州仪器(Texas Instruments)推出的一款高速数据采集板，专门用于毫米波雷达信号的采集和处理。是毫米波雷达系统开发和测试中的重要工具，其提供了丰富的配置选项和接口，用户可以根据具体需求对数据采集参数进行灵活配置，包括采样率、数据格式、触发方式等。DCA1000 支持多通道数据采集，可以同时采集多个通道的雷达信号数据，实现对多目标的同时跟踪和定位。DCA1000 数据采集板具有高速、大带宽、灵活配置、多通道支持等优势，适用于各种毫米波雷达系统的开发、测试和应用，是研究人员和工程师在毫米波雷达领域的重要工具之一。

AWR1642 与 DCA1000 的配合使用，提供了一个灵活而强大的平台，使开发者能够有效地开发和测试基于毫米波雷达的非接触式生命体征检测方案：

首先，将 AWR1642 雷达传感器与 DCA1000 数据采集卡通过 LVDS 接口连接。这种连接允许高速数据的传输。同时，需要将 DCA1000 通过 USB 或以太网接口连

接到计算机，以便于数据的传输和控制指令的发送。

其次，使用德州仪器提供的雷达工作室(Radar Studio)或其他相应的软件工具在计算机上配置 AWR1642 传感器。这包括雷达的工作频率、帧率、采样率、脉冲发射的配置等，这些参数都会直接影响雷达的性能和适用场景。

再次，配置完成后，AWR1642 根据设置的参数运行，开始发射和接收信号，捕捉目标信息。DCA1000 实时接收来自 AWR1642 的原始数据，并通过预先设置的接口(USB 或以太网)传输到计算机上。

最后，在计算机上，我们可以利用各种软件工具对采集到的数据进行处理和分析，例如使用 MATLAB、Python 或特定的信号处理软件进行目标检测、跟踪和分类等操作。

5.1.3 参考心率带

在进行使用 AWR1642 雷达传感器进行心率检测时，我们将接触式心率传感器 (Polar H10)作为心率检测的参考仪器。Polar H10 具备医疗级别的精准性，能够提供准确可靠的心率数据。作为行业领先的心率传感器，Polar H10 具有稳定可靠的性能，能够在不同环境条件下进行可靠的心率监测。Polar H10 心率传感器的实物展示如下图 5-3 所示：



图 5-3 Polar H10 心率传感器

5.1.4 实验环境

实验环境为复杂的室内环境，有 30 名被测者(15 名男性和 15 名女性)，待测人员坐在雷达前方 0.5-1m 处，胸腔正对雷达进行测量，实验中并不要求被测人员处于完全静止状态，存在小幅度运动。在数据采集的同时，采用 Polar H10 心率带对心跳速率进行记录，实测数据的采集长度为 60s，记录的结果折算成每分钟的心率。心率检测场景如图 5-4 所示。




图 5-4 心率检测场景图

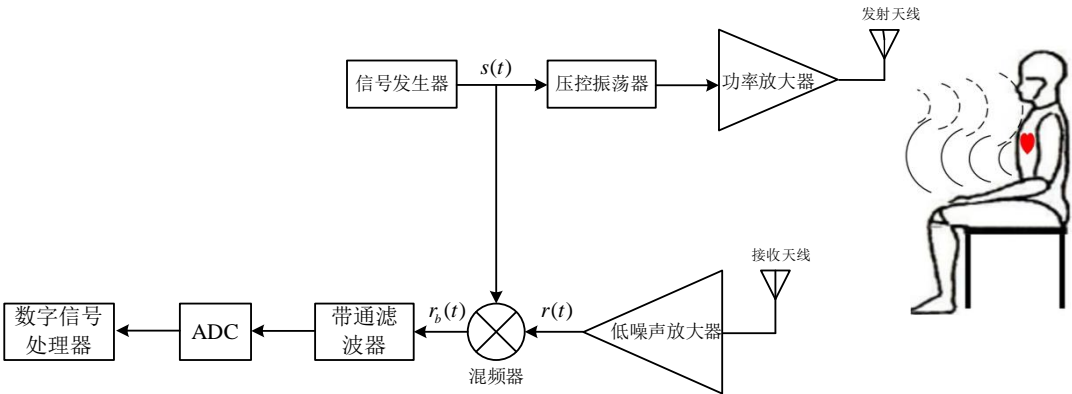


图 5-5 心率检测示意图

5.1.5 参数配置

(1) 天线配置

AWR1642 采用一发四收的一维线阵天线布局，如下图 5-6 所示。在心率检测中，只需要一个 TX/RX 天线就能够进行单人的心率检测。




图 5-6 收发天线模拟示意图

(2) 发射波形配置

表 5-1 详细描述了实验中所采用的 FMCW 雷达的发射波形配置参数。每个数据帧都包含两个 chirp，但在实际处理中，我们只利用了每个数据帧中的第一个 chirp。

表 5-1 发射波形参数配置

发射波形配置参数	配置参数
起始频率	77 GHz
带宽	3.99 GHz
时宽	57 μs
TX 启动时间	1 μs
ADC 启动时间	6 μs
ADC 实际采样时间	50 μs
快时间采样频率	4 MHz
采样点数	200
慢时间采样频率	20 Hz
帧周期	50 ms

5.1.6 实验评价指标

本文使用平均绝对误差(MAE)来评估不同处理方案的心率估计准确性，MAE 的计算公式可以表示为：

$$MAE = \frac{\sum_{i=1}^N |BPM_{true}(i) - BPM_{est}(i)|}{N} \quad (5-1)$$

其中, BPM_{true} 为 Polar H10 测量的参考心率值, BPM_{est} 为本文所提方案得到的心率估计值, N 代表每组实测数据中滑动事件窗口的总数。

5.2 基于 FMCW 雷达的心率检测处理框架的性能评估

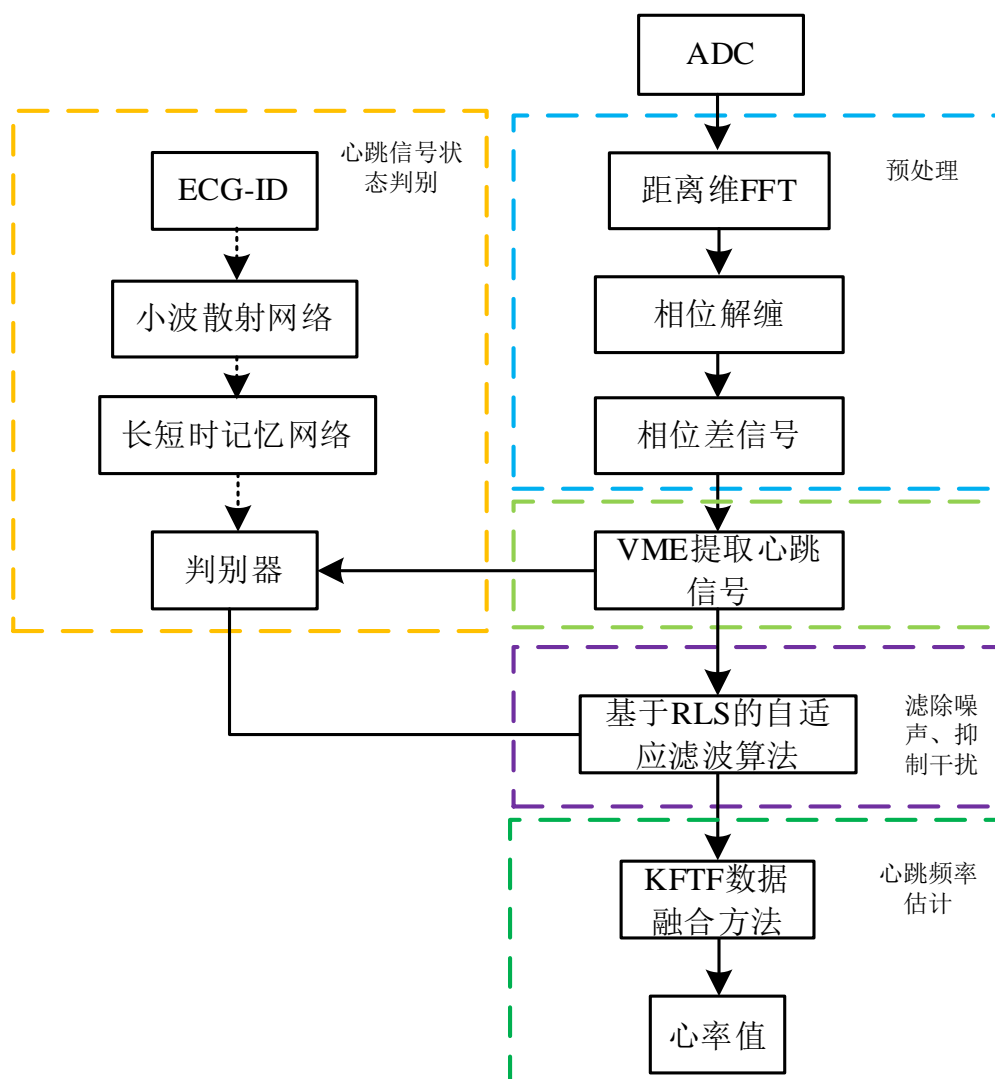


图 5-7 基于 FMCW 雷达的心率检测处理框架

本文提出的基于 FMCW 雷达的心率检测处理方案主要涵盖以下几个步骤：

(1) 针对混频后得到的雷达中频信号，我们进行预处理，以获取含有呼吸和心跳信号的生命体征信号。

(2) 使用 VME 算法将心跳信号从生命体征信号中提取出来。

(3) 通过用静止状态的心跳信号和运动状态的心跳信号训练 WSN-LSTM，然后判断当前心跳信号的状态，为后续基于 RLS 的自适应滤波算法中参考信号的选择提供指示。

(4) 使用基于 RLS 算法的自适应滤波滤除心跳信号中的呼吸谐波、运动伪影和交调信号等干扰。

(5) 对经滤除相关干扰后的信号应用 KFTF 方法进行心率估计，以获得准确的心率数值。在 KFTF 进行心率估计的过程中，我们将滑动窗口的参数设定为每个窗口持续的时间为 25.6 秒，步长为 1 秒。图 5-7 展示了所提出的基于 FMCW 雷达的心率检测方案的流程图。

为了确认我们提出的方案在不同的目标状态下进行心率检测的适用性，我们通过与最常用的基于 VMD 结合 FFT 的心率检测方案^[57]以及最新的基于 VME 结合 FFT 的心率检测方案^[58]与本文方案进行了比较，验证本文所提方案的精确性和鲁棒性。与此同时，我们选择了 Polar H10 心率带的数据作为参考心率曲线。

5.2.1 静止状态下心率检测结果分析




图 5-8 心率曲线图

图 5-8 显示了在被测目标静止状态下获取的一组生命体征数据，分别使用了本文提出的方案、文献[57]所提出的心率检测方案和文献[58]提出的心率检测方案得到的心率曲线。在图中，绿色表示文献[58]提出的心率检测方案，蓝色代表基于文献[57]所提出的心率检测方案，粉色代表本文提出的心率检测方案。

如图 5-8 所示，本文所提出的心率检测方案与参考心率曲线基本一致，其 MAE 为 1.42bpm。文献[58]提出的心率检测方案和文献[57]所提出的心率检测方案的 MAE 分别为 2.82bpm、3.88bpm，在 17s 至 35s 时，存在比较严重的偏移现象，并与实际心率的变化趋势有偏移点，相比之下基于深度学习的 KFTF 的心率估计曲线与参考心率一致性较好。

表 5-2 不同心率检测方案在静止状态下的性能对比

被测者	性别	VMD 方案	VME 方案	本文所提方案
		MAE/bpm	MAE/bpm	MAE/bpm
1	男	4.08	3.28	0.45
2	男	5.97	3.34	1.28
3	男	1.65	2.6	1.62
4	男	2.82	1.94	1.82
5	男	1.62	0.71	0.62
6	男	1.91	1.43	0.97
7	男	2.45	1.42	1.51
8	女	2.68	1.62	1.28
9	女	2.14	1.05	1.34
10	女	3.08	1.2	0.71
11	女	2.22	3.74	2.94
12	女	1.71	3.22	0.68
13	女	4.02	1.65	2.40
14	女	2.62	1.48	1.44
15	女	3.11	2.77	1.47
平均值		3.13	2.23	1.36
标准差		2.29	1.25	0.67

在表 5-2 中，我们呈现了本文提出的解决方案在静态状态下与文献[58]提出的

心率检测方案和文献[57]所提出的心率检测方案的比较结果。从表 5-2 可以观察到, 本文提出的方案的心率检测结果的平均 MAE 为 1.36bpm, 而文献[57]所提出的心率检测方案和文献[58]提出的心率检测方案的 MAE 分别为 2.23bpm 和 3.13bpm。可以看出经深度学习的指示经基于 RLS 的自适应滤波后, 而后使用 KFTF 谱估计方法进行心率值估计, 对处于静止状态的情况有小幅度的性能提升, 并且由三者标准差对比可以看出, 本文所提出的方案鲁棒性更强。

5.2.2 运动状态下心率检测结果分析

相较于静止状态下的心率检测, 运动状态下心跳信号所受的干扰更多、更强、更难分离。在运动状态下, 心跳信号不仅受到身体随机运动引起的干扰、其他干扰和噪声, 以及呼吸、心跳信号基波及其谐波和差拍等信号成分, 还受到身体运动造成的运动伪影的影响, 所以对于运动状态下的心率检测更为艰难。

为了验证所提出的方案能够在身体运动状态下同样性能较好, 我们使用受试者 1 的数据将所提出的方案的心率检测性能与文献[58]提出的心率检测方案和文献[57]所提出的心率检测方案进行了比较, 并选择 Ploar H10 心率带的数据作为参考心率曲线。

我们选取被测试的 15 人中的第一名被测者进行分析, 由图 5-9 观察到文献[58]提出的心率检测方案和文献[57]所提出的心率检测方案在某些时间节点上与参考结果存在较大偏差, 这可能是由于呼吸谐波、交调信号、运动伪影或其他噪声干扰导致的。这些算法的性能可能会受到这些干扰因素的影响, 从而导致估计结果的不稳定性。与文献[58]提出的心率检测方案和文献[57]所提出的心率检测方案相比, 本文所提方案在整体上表现出较高的稳定性, 大部分估计结果都在误差允许范围内, 且最大误差不超过 5bpm。这表明本文所提方案在应对呼吸谐波、交调信号、运动伪影等干扰时具有较好的性能。同时显示出较高的心率估计准确度, 这是因为它能够有效地应对各种干扰因素, 并产生与参考结果相比较为稳定和准确的估计值。这表明在运动状态下的心率检测方面具有很好的应用潜力。




图 5-9 心率曲线图

根据表 5-3 的数据，我们运用提出的心率检测框架和文献[58]提出的心率检测方案和文献[57]所提出的心率检测方案处理了 15 名受试者在运动过程中的实测生命体征数据，并计算了每组心率估计结果的 MAE。从表 5-3 可以看出，本文提出的方案的心率检测结果的平均 MAE 为 2.29bpm，而文献[58]提出的心率检测方案和文献[57]所提出的心率检测方案的 MAE 分别为 4.34bpm 和 2.92bpm。可以看出经深度学习的指示经基于 RLS 的自适应滤波后，而后使用 KFTF 谱估计方法进行心率值估计，对处于运动状态的情况有大幅度的性能提升，可以消除身体运动、身体随机运动引起的干扰、其他干扰和噪声，以及呼吸、心跳基波及其谐波和差拍信号等干扰。并且由三者标准差对比可以看出，本文所提出的方案鲁棒性更强。

表 5-3 不同心率检测方案在运动状态下的性能对比

被测者	性别	VMD 方案	VME 方案	本文所提方案
		MAE/bpm	MAE/bpm	MAE/bpm
1	男	2.74	2.45	2.34
2	男	2.34	1.42	1.28
3	男	1.8	1.4	1.4
4	男	5.08	2.02	3.25
5	男	2.94	3.74	2.4
6	男	15.45	3.45	4.02
7	男	4.25	3.91	2.57
8	女	5.91	3.42	3.11
9	女	3.68	4.2	2
10	女	4.91	4.08	3.3
11	女	1.71	1.17	1.34
12	女	1.2	1.02	1.2
13	女	3.05	3.37	2.94
14	女	1.71	1.51	1.71
15	女	8.37	6.68	1.57
平均值		4.34	2.92	2.29
标准差		3.62	1.55	0.88

5.3 本章小结

本章节介绍了如何使用 AWR1642 雷达进行生命体征检测的参数配置, 进行详细的解释和说明, 包括雷达的工作频率、带宽、采样率等参数, 以及如何根据实验需求进行调整和优化。进而采集实测生命数据来验证所提出的心率方案的有效性, 同时提供更详细的实验设备和场景描述, 包括雷达放置的位置、被测对象的位置和状态。结合现有基于毫米波雷达非接触式生命体征检测的文献, 与本文所提方案进行对比, 对实验结果进行更深入的分析 and 讨论, 验证其准确率和可靠性, 强调所提出的心率方案在生命体征检测领域的重要性和实用性。

6 总结和展望

6.1 研究工作总结

针对基于 FMCW 雷达的非接触式不同状态下心率检测这一难题，本文提出了一种基于深度学习的心率检测方案，具体工作如下：

（1）我们详细描述了雷达信号的初始处理流程，其主要目标是从原始数据中提取含有生命体征信息的相位数据。在这个处理过程中，我们使用了静态杂波过滤技术，以消除来自静态物体反射的杂波干扰，可以有效地净化雷达信号，提取出更纯净、更可靠的生命体征信息，为后续的信号处理和分析工作奠定良好的基础，而后通过 VME 将心跳信号从生命体征信号中提取出来。

（2）主要介绍了基于小波散射网络-长短期记忆网络模型对心跳信号状态进行判别，通过小波散射网络能够提供心跳信号在时频域上的特征，并生成散射特征系数。LSTM 是专门设计用于处理时序数据的递归神经网络。小波散射网络提取的时频域特征和 LSTM 学到的时序依赖关系被融合在一起，形成对心跳信号的综合表示。在判断心跳信号处于静止状态或身体微动状态后，基于 RLS 算法的自适应滤波器，根据心跳信号的状态选择相应的参考信号。解决了不同状态下的心跳信号所受的干扰存在较大的差异，滤波效果较差的问题，提取出来了较为纯净的心跳信号。

（3）主要介绍了基于卡尔曼滤波的时频域数据融合方法。针对心率估计过程中受到噪声和干扰影响，从而降低心率估计的准确性和鲁棒性的问题，本文提出了一种全新的心率估计方法，称之为 KFTF。KFTF 方法的心率估计流程分为三个主要步骤。首先，通过自适应滤波对心跳信号进行处理，并利用峰-谷差值进行时域心率估计。其次，在频域上使用 CZT(Chirp Z-Transform)提高心率信号的估计精度，实现频域心率估计。最后，通过卡尔曼滤波将时域和频域的心率估计进行匹配融合，得到最终的心率值。

（4）将以上所使用的雷达信号预处理流程、VME 算法、小波散射网络-长短期

期记忆网络、基于 RLS 的自适应滤波、以及 KFTF 相结合，形成了一个完整的基于深度学习的毫米波雷达非接触生命体征检测技术研究方案。通过这些实验过程和结果分析，可以全面地展示所提算法的性能和可行性，并验证其在特定应用场景下的有效性和优越性，说明了所提算法的应用前景和推广价值。

6.2 后续研究展望

在实际应用中，深度学习驱动的毫米波雷达非接触生命体征检测技术研究方案在单个人体目标处于身体运动状态或者是静止状态下的检测场景，均能估测出较为准确的心率估计结果。然而，尽管本方案具备显著优势，但仍存在一定的局限性：

数据的局限性：本文所使用的训练集数据均来源于实验室广泛收集的生命体征数据，具有一定的局限性，实验数据缺乏多地区、多人种以及多体质的不同数据，缺乏世界公认的权威数据库，供大家进行学习和训练。与此同时，本文的训练集较小，不能涵盖全部的情况和身体运动种类。

运动干扰处理挑战：身体运动会导致信号的频谱结构发生变化，从而对心率检测造成干扰。当前方案的运动幅度较小，缺乏对剧烈运动干扰的有效处理方法，如跑步或激烈运动时，心率检测的准确性可能会受到较大影响。

个体差异影响：不同个体的生理特征存在较大差异，包括心率变化范围、心跳信号强度等。方案可能对特定人群的适用性限制较大，需要针对不同人群的生理特征进行更加精细化的研究和优化。

数据采集和处理复杂度高：方案需要大量的数据采集和处理工作，并且可能需要复杂的算法模型和计算资源，需要能够跟随心率快速变化的低运算量高精度算法。这会增加方案的实施成本和复杂性，限制了其在实际应用中的推广和应用。

针对这些局限性，未来的研究需要进一步深入探讨，并提出有效的解决方案。例如，可以通过建立完善权威的数据集、优化算法模型、改进数据处理技术等方式来克服这些挑战，从而提高基于深度学习的毫米波雷达生命体征检测技术的实用性和可靠性。

参考文献

- [1] H. Abuellla and S. Ekin, Non-Contact Vital Signs Monitoring Through Visible Light Sensing[J]. IEEE Sensors Journal, 2020,20(7): 3859-3870.
- [2] H. K. Kim and M. H. Sunwoo, An Automated Cardiac Arrhythmia Classification Network for 45 Arrhythmia Classes Using 12-Lead Electrocardiogram[J]. IEEE Access, 2024,12:44527-44538.
- [3] 罗奕麟. 如何破解老龄化社会中的养老问题? [N]. 韶关日报,2024-03-21(A06).
- [4] N. Ji et al., Recommendation to Use Wearable-Based mHealth in Closed-Loop Management of Acute Cardiovascular Disease Patients During the COVID-19 Pandemic[J]. IEEE Journal of Biomedical and Health Informatics,2021,25(4):903-908.
- [5] J. Lee and K. H. Chon, Time-Varying Autoregressive Model-Based Multiple Modes Particle Filtering Algorithm for Respiratory Rate Extraction From Pulse Oximeter[J]. IEEE Transactions on Biomedical Engineering,2011,58(3):790-794.
- [6] H. Rashtian, S. S. Torbaghan, S. Rahili, M. Snyder and N. Aghaeepour, Heart Rate and CGM Feature Representation Diabetes Detection From Heart Rate: Learning Joint Features of Heart Rate and Continuous Glucose Monitors Yields Better Representations[J]. IEEE Access, 2021,9:83234-83240.
- [7] 冯玉竹,魏剑南,马玉鑫,等.基于物联网的可穿戴设备及生命体征监测系统[J].工业技术创新,2023,10(05):106-115.
- [8] T. Ye et al., The Application Situation of the Non-contact On-line Detection Technology on Overhead Equipment in Distribution Network[C]//2018 International Conference on Power System Technology (POWERCON). Guangzhou, China, 2018: 4010-4014.
- [9] W. Dong, X. Cheng and D. Yao, Soft body sensor networks: Architectures and

- Applications[C]//2020 IEEE International Conference on Networking, Sensing and Control (ICNSC). Nanjing, China, 2020:1-6.
- [10] C. Kang, M. Kim, K. Kim and S. Lee, Contact Part Detection From 3D Human Motion Data Using Manually Labeled Contact Data and Deep Learning[J]. IEEE Access, 2023, 11:127608-127618.
- [11] T. Adiono et al., Respinos: A Portable Device for Remote Vital Signs Monitoring of COVID-19 Patients[J]. IEEE Transactions on Biomedical Circuits and Systems, 2022, 16(5):947-961.
- [12] L. Qiao et al., Learning-Refined Integral Null Space Pursuit Algorithm for Noncontact Multisubjects Vital Signs Measurements Using SFCW-UWB and IR-UWB Radar[J]. IEEE Transactions on Instrumentation and Measurement, 2022, 71:1-13.
- [13] Li Mu, Xiaohui Zhang, Tong Xiangqian and Qing Liu, A novel PN-coded FMCW radar design and implementation[C]//Proceedings of 2011 IEEE CIE International Conference on Radar. Chengdu, 2011: 1004-1007.
- [14] J. Liu, K. Zhang, W. He, J. Ma, L. Peng and T. Zheng, Non-contact Human Fatigue Assessment System Based on Millimeter Wave Radar[C]//2021 IEEE 4th International Conference on Electronics Technology (ICET). Chengdu, China, 2021: 173-177.
- [15] W. Lv, Y. Zhao, W. Zhang, W. Liu, A. Hu and J. Miao, Remote Measurement of Short-Term Heart Rate With Narrow Beam Millimeter Wave Radar[J]. IEEE Access, 2021, 9: 165049-165058.
- [16] Z. Aoujil, M. Hanine, E. S. Flores, M. A. Samad and I. Ashraf, Deep Learning and Behavioral Economics: A Bibliographic Analysis of Research Field[J]. IEEE Access, 2023, 11: 139367-139394.
- [17] G. Cay et al., Recent Advancement in Sleep Technologies: A Literature Review on

- Clinical Standards, Sensors, Apps, and AI Methods[J]. IEEE Access, 2022,10: 104737-104756.
- [18] M. Brulc, T. Deleruyelle, A. Loussert, P. Laurent, R. Grisot and J. -P. Caruana, Cardiac Signature Detection and Study Using Contactless Technology: Millimeter-Wave FMCW Radar[J]. IEEE Open Journal of Instrumentation and Measurement, 2023, 2: 1-8.
- [19] Ren, O. Ma, H. Ji and X. Liu, Human Posture Recognition Using a Hybrid of Fuzzy Logic and Machine Learning Approaches[J]. IEEE Access, 2020, 8: 135628-135639.
- [20] Zheng and X. Zhou, Cross-pose color facial expression recognition using transductive transfer linear discriminant analysis[C]//2015 IEEE International Conference on Image Processing (ICIP). Quebec City, QC, Canada, 2015: 1935-1939.
- [21] S. W. Kim, S. B. Choi, Y. -J. An, B. -H. Kim, D. W. Kim and J. -G. Yook, Heart Rate Detection During Sleep Using a Flexible RF Resonator and Injection-Locked PLL Sensor[J]. IEEE Transactions on Biomedical Engineering, 2015, 62(11): 2568-2575.
- [22] 兰笑然. 基于人机交互的智能生命检测仪适老性设计研究[D].秦皇岛: 燕山大学,2022.
- [23] C. -C. Sun, Y. -H. Wang and M. -H. Sheu, Fast Motion Object Detection Algorithm Using Complementary Depth Image on an RGB-D Camera[J]. IEEE Sensors Journal, 2017, 17(17): 5728-5734.
- [24] A. Shokouhmand, S. Eckstrom, B. Gholami and N. Tavassolian, Camera-Augmented Non-Contact Vital Sign Monitoring in Real Time[J]. IEEE Sensors Journal, 2022, 22(12):11965-11978.
- [25] D. -M. Chian, C. -K. Wen, C. -J. Wang, M. -H. Hsu and F. -K. Wang, Vital Signs Identification System With Doppler Radars and Thermal Camera[J]. IEEE Transactions on Biomedical Circuits and Systems, 2022, 16(1):153-167.
- [26] H. Yang, D. Wang, Q. Yin, Y. Gao and L. Zheng, Study on thermal expansion based
-

- on CCD thermoreflectance imaging technology[C]//2022 23rd International Conference on Electronic Packaging Technology (ICEPT). Dalian, China, 2022: 1-6.
- [27] D. Fuentes, J. Yung, J. D. Hazle, J. S. Weinberg and R. J. Stafford, Kalman Filtered MR Temperature Imaging for Laser Induced Thermal Therapies[J]. IEEE Transactions on Medical Imaging, 31(4): 984-994.
- [28] P. Zhu, L. Tian and Y. Cheng, Improvement of Defect Feature Extraction in Eddy Current Pulsed Thermography[J]. IEEE Access, 2019, 7:48288-48294.
- [29] 朱铨凯. 基于连续波雷达传感的微弱信号测量和定位[D].杭州: 浙江大学,2023.
- [30] 宋腾飞. 毫米波雷达人体正常与异常行为检测与识别[D].石家庄: 石家庄铁道大学,2023.
- [31] S. Kueppers, R. Herschel and N. Pohl, Advances in compact integrated multichannel millimeter wave radar systems using SiGe BiCMOS technology (Focused session on highly-integrated millimeter-wave radar sensors in SiGe BiCMOS technologies)[C]//2018 22nd International Microwave and Radar Conference (MIKON). Poznan, Poland, 2018: 330-333.
- [32] R. K. Sharma et al., Robust Radar Altimeter Processor[J]. IEEE Transactions on Radar Systems, 2024, 2: 372-379.
- [33] A. B. Vattulainen, S. Rahman and D. A. Robertson, G-Band FMCW Doppler Radar for Close-Range Environmental Sensing[J]. IEEE Transactions on Radar Systems, 2024, 2: 355-371.
- [34] P. Zhang and Z. Xu, A Dual-Frequency Phase Ambiguity Resolution Method for FMCW Radar High-Accuracy Ranging[J]. IEEE Transactions on Instrumentation and Measurement, 2007, 87(06): 1224-1233
- [35] R. A. I. Asyari, M. Z. Wiranata, C. Li, R. B. V. B. Simorangkir and D. Teichmann, 60 GHz FMCW Millimeter Wave Radar Assisted With Dual-Layer Wideband Flexible Metasurface for Accurate Wrist Pulse Monitoring[J]. IEEE Sensors Letters,

2024, 8(3):1-4.

- [36] 陈泽坤. FMCW雷达生命体征检测中身体运动效应抑制技术研究[D].烟台: 烟台大学,2024.
- [37] 薛毅松. 基于毫米波雷达的非接触式健康监测系统研究[D].成都: 电子科技大学,2023.
- [38] 王玗琪. 基于FMCW毫米波雷达的生命体征信号检测算法研究[D].海口: 海南大学,2024.
- [39] 崔英杰, 刘云学, 宋健强, 等. 基于M-Rife算法的梯形波FMCW雷达多目标检测技术研究[J].电子设计工程, 2021, 29(24): 69-74+79.
- [40] J. Liu, Y. Li, C. Li, C. Gu and J. -F. Mao, Accurate Measurement of Human Vital Signs With Linear FMCW Radars Under Proximity Stationary Clutters[J]. IEEE Transactions on Biomedical Circuits and Systems, 2021,15(6): 1393-1404.
- [41] Y. Liu, N. Li, Y. Zhang, J. Cheng, T. Ma and W. Yue, Research on non-contact vital sign detection based on 24 GHz FMCW radar[C]//2023 International Conference on Microwave and Millimeter Wave Technology (ICMMT). Qingdao, China, 2023: 1-3.
- [42] R. K. Arumugam, R. Herschel, I. Masri, K. Burger and W. Reitmeier, Digital FIR filtering for static clutter suppression in low resolution MIMO radar[C]//2021 18th European Radar Conference (EuRAD). London, United Kingdom, 2022: 289-292.
- [43] Z. Liu, Y. Kong, X. Zhang, J. Wu and W. Lu, Vital Sign Extraction in the Presence of Radar Mutual Interference[J]. IEEE Signal Processing Letters, 2020, 27:1745-1749.
- [44] Y. -H. Wang and S. -H. Cheng, Boundary Effects for EMD-Based Algorithms[J]. IEEE Signal Processing Letters, 2022, 29:1032-936.
- [45] S. Li, J. Zhao, Y. Wu, S. Bian and G. Zhai, Prior Frequency Information Assisted VMD Method for SBP Sonar Data Noise Removal[J]. IEEE Geoscience and Remote Sensing Letters, 2023, 20: 1-5.

- [46] J. Shen, P. Lou, L. Yuan, S. Lyu and Y. Lu, VME-Transformer: Enhancing Visual Memory Encoding for Navigation in Interactive Environments[J]. IEEE Robotics and Automation Letters, 2024, 9(1):643-650.
- [47] H. Sun, J. Guo and L. Fang, Improved Singular Value Decomposition (TopSVD) for Source Number Estimation of Low SNR in Blind Source Separation[J]. IEEE Access, 2017, 5:26460-26465.
- [48] I. S. Akila and R. Venkatesan, A Fuzzy Based Energy-aware Clustering Architecture for Cooperative Communication in WSN[J]. The Computer Journal, 2016,59(10): 1551-1562.
- [49] L. Liang, D. Xie, L. Jin, J. Xu, M. Li and L. Lin, Region-aware scattering convolution networks for facial beauty prediction[C]//2017 IEEE International Conference on Image Processing (ICIP). Beijing, China, 2017: 2861-2865,
- [50] X. Shu, L. Zhang, Y. Sun and J. Tang, Host-Parasite: Graph LSTM-in-LSTM for Group Activity Recognition[J]. IEEE Transactions on Neural Networks and Learning Systems, 2021, 32(2):663-674.
- [51] W. Gao, J. Chen and C. Richard, Theoretical Analysis of the Performance of the Data-Reuse RLS Algorithm[J]. IEEE Transactions on Circuits and Systems II: Express Briefs, 2024, 71(1): 490-494.
- [52] B. H. Stafford et al., Pinning Centers in ISD-MgO Coated Conductors via EB-PVD[J]. IEEE Transactions on Applied Superconductivity, 2016, 26(3):1-5.
- [53] 赵媛. 基于FMCW雷达的生命特征信号干扰抑制和提取技术研究[D]. 烟台: 烟台大学,2024.
- [54] K. Erlandsson, A. Wirth, K. Thielemans, I. Baistow, A. Cherlin and B. F. Hutton, Design of a Low-Dose, Stationary, Tomographic Molecular Breast Imaging System Using 3-D Position Sensitive CZT Detectors[J]. IEEE Transactions on Radiation and Plasma Medical Sciences, 2023,7(3): 225-232.

- [55] S. Wang, J. Feng and C. K. Tse, Analysis of the Characteristic of the Kalman Gain for 1-D Chaotic Maps in Cubature Kalman Filter[J]. IEEE Signal Processing Letters, 2013, 20(3): 229-232.
- [56] A. EWART, J. S. MARSH, S. C. MILNER, A. R. DUNCAN, B. S. KAMBER and R. A. ARMSTRONG, Petrology and Geochemistry of Early Cretaceous Bimodal Continental Flood Volcanism of the NW Etendeka, Namibia. Part 2: Characteristics and Petrogenesis of the High-Ti Latite and High-Ti and Low-Ti Voluminous Quartz Latite Eruptives[J]. Journal of Petrology, 2004, 45(1):107-138.
- [57] L. Qu, C. Liu, T. Yang and Y. Sun, Vital Sign Detection of FMCW Radar Based on Improved Adaptive Parameter Variational Mode Decomposition[J]. IEEE Sensors Journal, 2023, 23(20): 25048-25060.
- [58] M. Zhou, Y. Liu, S. Wu, C. Wang, Z. Chen and H. Li, A Novel Scheme of High-Precision Heart Rate Detection With a mm-Wave FMCW Radar[J]. IEEE Access, 2023, 11: 85118-85136.